AE系列篇-04.CVAE理论篇: 从“无条件生成”到“条件生成”

1. VAE的问题与CVAE的引入

1.1 VAE的局限性

变分自编码器（VAE）是一种强大的生成模型，它通过学习数据的潜在表示（latent representation）来生成新样本。VAE通过正则化潜在空间，使得整个潜在空间都具有生成能力，可以从标准正态分布 $\mathcal{N}(0, I)$ 中采样潜在变量 z，然后通过解码器生成新的数据样本。

然而，传统的VAE在处理一些需要特定条件控制的生成任务时显得力不从心。具体来说:

无法控制生成内容:VAE从标准正态分布随机采样潜在变量 z，生成的内容是完全随机的，无法指定生成特定类别的样本

1.2 CVAE的解决方案

在图像生成任务中，我们可能希望根据特定标签（ 数字“5”）来生成相应的图像，而不是随机生成一个图像

为了增强VAE的灵活性和可控性，提出了**条件变分自编码器（Conditional Variational Autoencoder, CVAE）**。CVAE允许我们在生成过程中加入额外的信息（条件），从而实现更加精确和可控的数据生成。

核心思想:在VAE的基础上，引入条件变量 c，使得生成过程依赖于条件信息。比 ，可以通过指定条件变量 c 来指导模型生成特定类别的样本。

为了更好地理解VAE和CVAE的区别，我们先回顾一下VAE的架构:

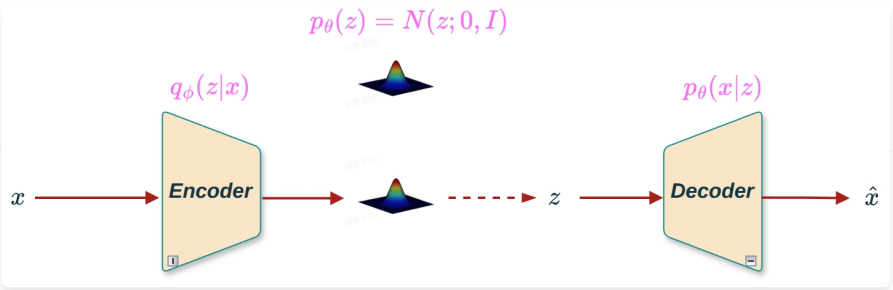


图1 VAE架构:编码器输出分布参数 (μ, σ)，通过重参数化采样 z，解码器重构输出 $\hat{x}$

---

2. CVAE的三个核心问题

于是自然而然出现了三个待解答的问题。

2.1 问题1:条件C加在VAE的哪个部分?

在CVAE中，条件变量 c 可以添加到VAE的不同位置，每种选择都会产生不同的模型变体:

选项1:条件只加在编码器（Encoder）

- 编码器:$q_\phi(z|x,c)$ - 编码时使用条件信息
- 解码器:$p_\theta(x|z)$ - 解码时不使用条件信息
- 特点:条件信息影响潜在表示 z，但不直接影响生成过程

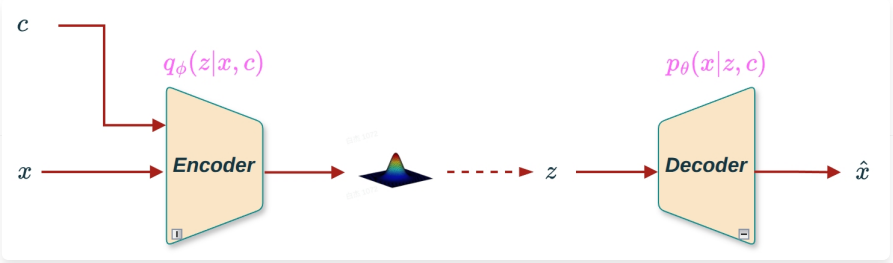


图2 选项1:条件只加在编码器

选项2:条件只加在解码器（Decoder）

- 编码器:$q_\phi(z|x)$ - 编码时不使用条件信息
- 解码器:$p_\theta(x|z,c)$ - 解码时使用条件信息
- 特点:潜在表示 z 与条件独立，条件信息只影响生成过程

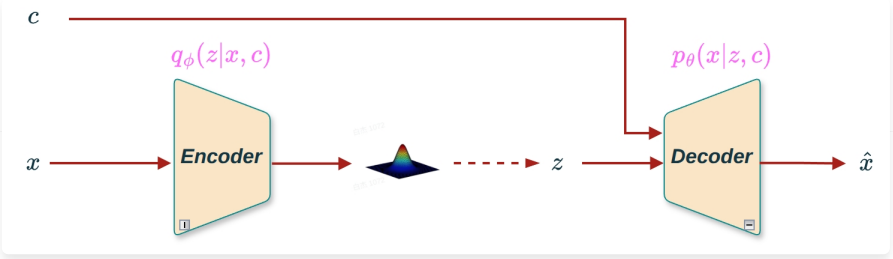


图3 选项2:条件只加在解码器

选项3:条件同时加在编码器和解码器

- 编码器:$q_\phi(z|x,c)$ - 编码时使用条件信息
- 解码器:$p_\theta(x|z,c)$ - 解码时使用条件信息
- 特点:条件信息既影响潜在表示，也影响生成过程，这是最常见的CVAE形式

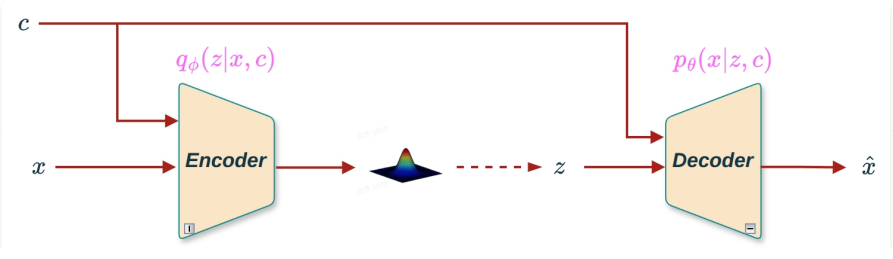


图4 选项3:条件同时加在编码器和解码器

2.2 问题2:条件c和潜在变量z是独立还是非独立的?

这是一个重要的理论问题，涉及先验分布 $p(z|c)$ 的选择:

情况1:c和z独立（Independent） - 假设:$p(z|c) = p(z) = \mathcal{N}(0, I)$ - 含义:条件 c 不影响潜在变量 z 的先验分布 - 实现:不需要额外的Prior网络，先验分布是固定的标准正态分布 - KL项:$\mathrm{KL}(q_\phi(z|x,c)\|p(z))$ 或 $\mathrm{KL}(q_\phi(z|x)\|p(z))$

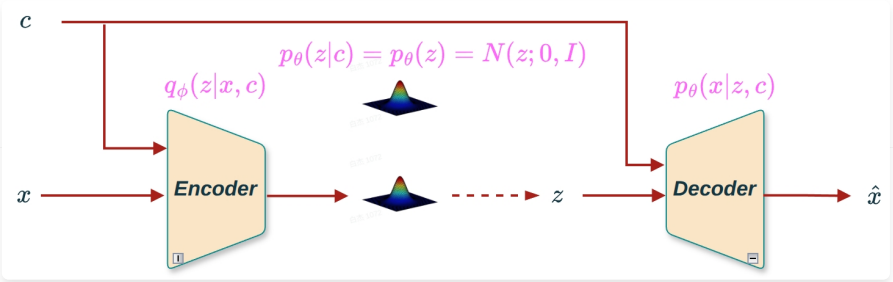


图5 情况1:c和z独立

情况2:c和z非独立（Dependent） - 假设:$p(z|c) = \mathcal{N}(\mu_{prior}(c), \sigma^2_{prior}(c))$ - 先验分布依赖于条件 - 含义:不同条件对应不同的潜在空间先验分布 - 实现:需要Prior网络来学习条件先验 $p(z|c)$ - KL项:$\mathrm{KL}(q_\phi(z|x,c)\|p(z|c))$ 或 $\mathrm{KL}(q_\phi(z|x)\|p(z|c))$

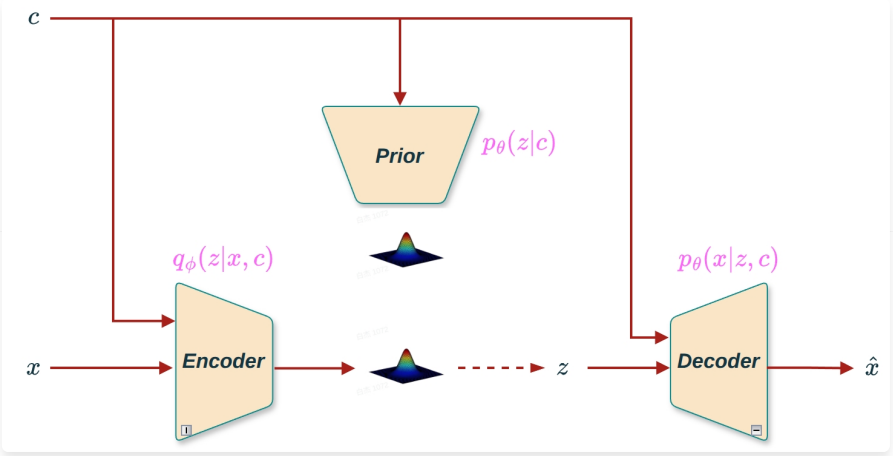


图6 情况2:c和z非独立

2.3 问题3:条件c如何编码?

条件变量 c 需要编码成数值向量才能输入神经网络，常见的编码方式有:

方式1:One-Hot编码 - 方法:将类别索引转换为独热向量 - 例 :类别3 → $[0, 0, 0, 1, 0, 0, 0, 0, 0, 0]$（MNIST的10个类别） - 优点:简单直观，不需要额外参数 - 缺点:维度等于类别数，当类别数很大时维度很高；编码是固定的，无法学习

方式2:Embedding编码 - 方法:使用可学习的嵌入层将类别索引映射为低维向量 - 例 :类别3 → 可学习的N维向量 - 优点:维度可自定义，通常比one-hot更紧凑；可以学习到类别之间的语义关系 - 缺点:需要额外的可学习参数

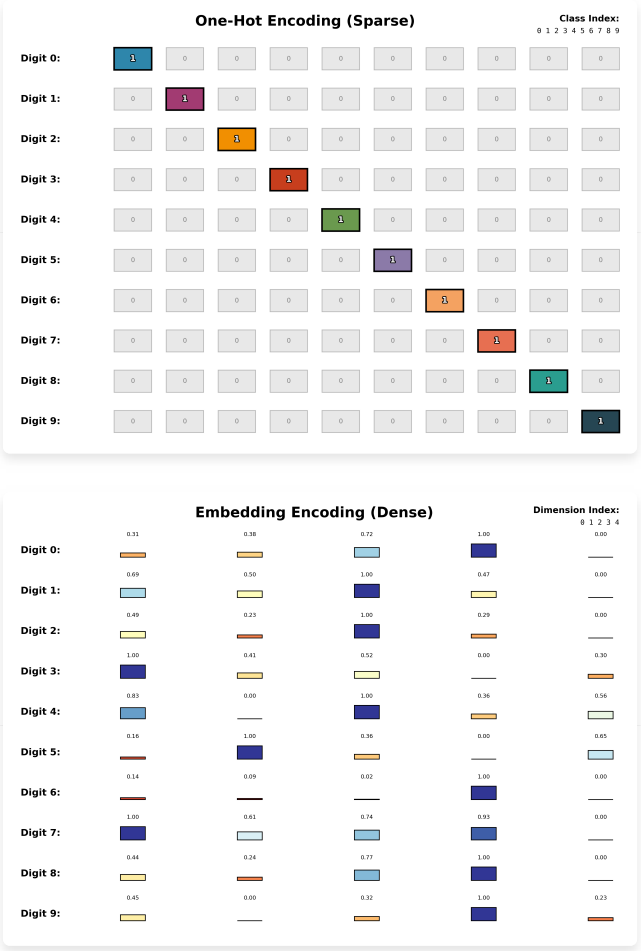


图7 条件编码方式:One-Hot编码（左）vs Embedding编码（右）

---

3. CVAE的ELBO推导与变体

3.1 CVAE的ELBO推导

在CVAE中，我们需要最大化条件对数似然 $\log p_\theta(x|c)$。与VAE类似，我们引入变分后验 $q_\phi(z|x,c)$ 来近似真实后验 $p_\theta(z|x,c)$。

条件对数似然:

$$\log p_\theta(x|c) = \log \int p_\theta(x|z,c)p_\theta(z|c)dz \tag{1}$$

引入变分后验:我们使用 $q_\phi(z|x,c)$ 来近似 $p_\theta(z|x,c)$。

ELBO推导:

展开KL散度:

$$
\begin{aligned}
D_{\mathrm{KL}}(q_\phi(\mathbf{z}|\mathbf{x},c)\|p_\theta(\mathbf{z}|\mathbf{x},c)) &= \int q_\phi(\mathbf{z}|\mathbf{x},c)\log\frac{q_\phi(\mathbf{z}|\mathbf{x},c)}{p_\theta(\mathbf{z}|\mathbf{x},c)}d\mathbf{z} \\
&= \int q_\phi(\mathbf{z}|\mathbf{x},c)\log\frac{q_\phi(\mathbf{z}|\mathbf{x},c)p_\theta(\mathbf{x}|c)}{p_\theta(\mathbf{z},\mathbf{x}|c)}d\mathbf{z} \\
&= \int q_\phi(\mathbf{z}|\mathbf{x},c)\big(\log p_\theta(\mathbf{x}|c) + \log\frac{q_\phi(\mathbf{z}|\mathbf{x},c)}{p_\theta(\mathbf{z},\mathbf{x}|c)}\big)d\mathbf{z} \\
&= \log p_\theta(\mathbf{x}|c) + \int q_\phi(\mathbf{z}|\mathbf{x},c)\log\frac{q_\phi(\mathbf{z}|\mathbf{x},c)}{p_\theta(\mathbf{z},\mathbf{x}|c)}d\mathbf{z} \\
&= \log p_\theta(\mathbf{x}|c) + \int q_\phi(\mathbf{z}|\mathbf{x},c)\log\frac{q_\phi(\mathbf{z}|\mathbf{x},c)}{p_\theta(\mathbf{x}|\mathbf{z},c)p_\theta(\mathbf{z}|c)}d\mathbf{z} \\
&= \log p_\theta(\mathbf{x}|c) + \mathbb{E}_{\mathbf{z}\sim q_\phi(\mathbf{z}|\mathbf{x},c)}[\log q_\phi(\mathbf{z}|\mathbf{x},c) - \log p_\theta(\mathbf{x}|\mathbf{z},c) - \log p_\theta(\mathbf{z}|c)] \\
&= \log p_\theta(\mathbf{x}|c) + D_{\mathrm{KL}}(q_\phi(\mathbf{z}|\mathbf{x},c)\|p_\theta(\mathbf{z}|c)) - \mathbb{E}_{\mathbf{z}\sim q_\phi(\mathbf{z}|\mathbf{x},c)}\log p_\theta(\mathbf{x}|\mathbf{z},c)
\end{aligned}
$$

重新排列后，我们有:

$$\log p_\theta(\mathbf{x}|c) = D_{\mathrm{KL}}(q_\phi(\mathbf{z}|\mathbf{x},c)\|p_\theta(\mathbf{z}|\mathbf{x},c)) + \mathcal{L}(\mathbf{x},c;\theta,\phi) \tag{2}$$

其中:

$$\mathcal{L}(\mathbf{x},c;\theta,\phi) = \mathbb{E}_{\mathbf{z}\sim q_\phi(\mathbf{z}|\mathbf{x},c)}\log p_\theta(\mathbf{x}|\mathbf{z},c) - D_{\mathrm{KL}}(q_\phi(\mathbf{z}|\mathbf{x},c)\|p_\theta(\mathbf{z}|c)) \tag{3}$$

$\mathcal{L}(\mathbf{x},c;\theta,\phi)$ 被称为**证据下界（Evidence Lower Bound, ELBO）**。由于KL散度总是非负的，我们有:

$$\log p_\theta(\mathbf{x}|c) \geq \mathcal{L}(\mathbf{x},c;\theta,\phi) \tag{4}$$

因此，**最大化ELBO等价于最小化KL散度**。

ELBO的组成:

1. **重构项（Reconstruction Term）**: $\mathbb{E}_{\mathbf{z}\sim q_\phi(\mathbf{z}|\mathbf{x},c)}\log p_\theta(\mathbf{x}|\mathbf{z},c)$ - 鼓励模型从潜在编码 $\mathbf{z}$ 和条件 c 重构原始输入 $\mathbf{x}$
2. **正则化项（Regularization Term）**: $-D_{\mathrm{KL}}(q_\phi(\mathbf{z}|\mathbf{x},c)\|p_\theta(\mathbf{z}|c))$ - 鼓励估计的后验分布 $q_\phi(\mathbf{z}|\mathbf{x},c)$ 接近条件先验分布 $p_\theta(\mathbf{z}|c)$

CVAE的损失函数:

在变分贝叶斯方法中，损失函数是ELBO的负值:

$$\mathcal{L}_{CVAE} = -\mathcal{L}(\mathbf{x},c;\theta,\phi) = -\mathbb{E}_{\mathbf{z}\sim q_\phi(\mathbf{z}|\mathbf{x},c)}\log p_\theta(\mathbf{x}|\mathbf{z},c) + D_{\mathrm{KL}}(q_\phi(\mathbf{z}|\mathbf{x},c)\|p_\theta(\mathbf{z}|c)) \tag{5}$$

通过最小化损失，我们实际上是在最大化生成真实数据样本（在给定条件 c 下）概率的下界。

与VAE相比，CVAE的ELBO有两处关键变化: 1. **重构项**: $\mathbb{E}_{\mathbf{z}\sim q_\phi(\mathbf{z}|\mathbf{x},c)}\log p_\theta(\mathbf{x}|\mathbf{z},c)$ - 解码器依赖于条件 c 2. **KL项**: $D_{\mathrm{KL}}(q_\phi(\mathbf{z}|\mathbf{x},c)\|p_\theta(\mathbf{z}|c))$ - 先验分布依赖于条件 c

可以看出，这就是最标准的CVAE的形式。接下来，我们来回答2中提出来的几个问题，关于c与z的独立性问题，以及c可以加在哪个位置?

3.2 变体1:c和z独立 vs 非独立

3.2.1 独立情况:$p(z|c) = p(z) = \mathcal{N}(0,I)$

假设:条件 c 和潜在变量 z 是独立的，先验分布不依赖于条件。

ELBO:

$$\mathcal{L}(x, c; \theta, \phi) = \mathbb{E}_{z \sim q_\phi(z|x,c)}[\log p_\theta(x|z,c)] - \mathrm{KL}(q_\phi(z|x,c) \| p(z)) \tag{6}$$

特点: - 不需要Prior网络，先验分布是固定的标准正态分布 - KL项简化为:$\mathrm{KL}(q_\phi(z|x,c) \| \mathcal{N}(0, I))$ - 计算简单，参数量较少

KL散度计算:

$$\mathrm{KL}(q_\phi(z|x,c) \| p(z)) = \mathrm{KL}(\mathcal{N}(\mu, \sigma^2 I) \| \mathcal{N}(0, I)) = \frac{1}{2} \sum_{i=1}^{H} [\mu_i^2 + \sigma_i^2 - 1 - \log \sigma_i^2] \tag{7}$$

3.2.2 非独立情况:$p(z|c) = \mathcal{N}(\mu_{prior}(c), \sigma^2_{prior}(c))$

假设:条件 c 和潜在变量 z 是非独立的，先验分布依赖于条件。

ELBO:

$$\mathcal{L}(x, c; \theta, \phi) = \mathbb{E}_{z \sim q_\phi(z|x,c)}[\log p_\theta(x|z,c)] - \mathrm{KL}(q_\phi(z|x,c) \| p_\theta(z|c)) \tag{8}$$

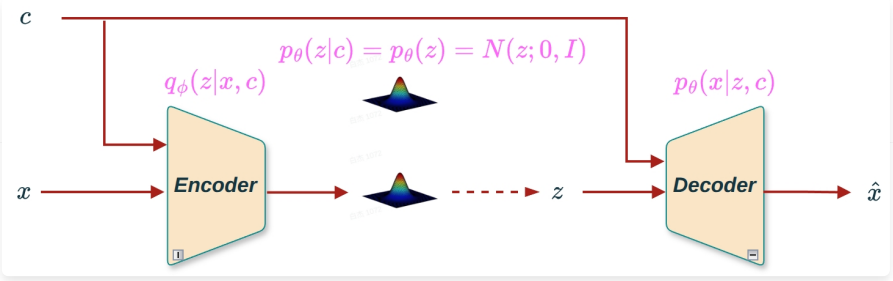
特点: - 需要Prior网络来学习条件先验 $p_\theta(z|c)$ - Prior网络输出:$\mu_{prior}(c), \sigma_{prior}(c)$ - 更灵活，可以建模不同条件对应的不同潜在空间结构

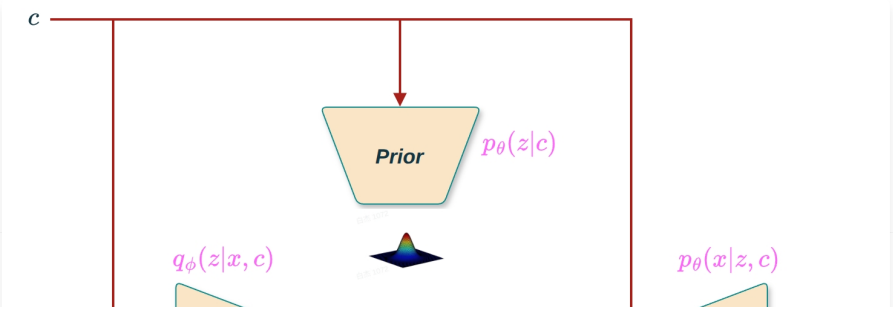
KL散度计算: 两个高斯分布之间的KL散度:

$$\begin{aligned} \mathrm{KL}(q_\phi(z|x,c) \| p_\theta(z|c)) &= \mathrm{KL}(\mathcal{N}(\mu_q, \sigma_q^2) \| \mathcal{N}(\mu_{prior}, \sigma^2_{prior})) \\ &= \frac{1}{2} \log \frac{\sigma^2_{prior}}{\sigma_q^2} + \frac{\sigma_q^2 + (\mu_q - \mu_{prior})^2}{2\sigma^2_{prior}} - \frac{1}{2} \end{aligned} \tag{9}$$

架构对比:

- 独立情况（左图）:无Prior网络，先验固定为 $\mathcal{N}(0, I)$
- 非独立情况（右图）:有Prior网络，先验依赖于 c





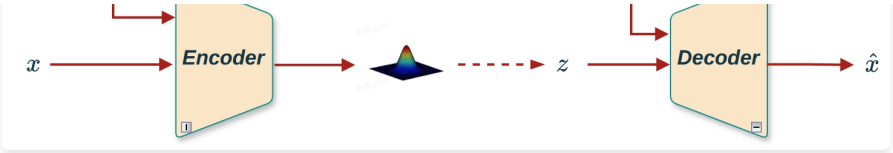


图8 CVAE的两种先验对比:独立情况（左，固定先验）vs 非独立情况（右，Prior网络学习先验 $p(z|c)$）

3.3 变体2:条件只加在解码器

模型定义: - 编码器:$q_\phi(z|x)$ - 不使用条件 c - 解码器:$p_\theta(x|z,c)$ - 使用条件 c - 先验:$p_\theta(z|c)$ 或 $p(z)$

ELBO: 果使用条件先验 $p_\theta(z|c)$:

$$\mathcal{L}(x,c;\theta,\phi) = \mathbb{E}_{z\sim q_\phi(z|x)}[\log p_\theta(x|z,c)] - \mathrm{KL}(q_\phi(z|x)\|p_\theta(z|c)) \tag{10}$$

果使用固定先验 $p(z)=\mathcal{N}(0,I)$:

$$\mathcal{L}(x,c;\theta,\phi) = \mathbb{E}_{z\sim q_\phi(z|x)}[\log p_\theta(x|z,c)] - \mathrm{KL}(q_\phi(z|x)\|p(z)) \tag{11}$$

特点: - 潜在表示 z 与条件 c 在编码阶段独立 - 条件信息只影响生成过程，不影响潜在表示的学习 - 适用于希望潜在表示与条件解耦的场景

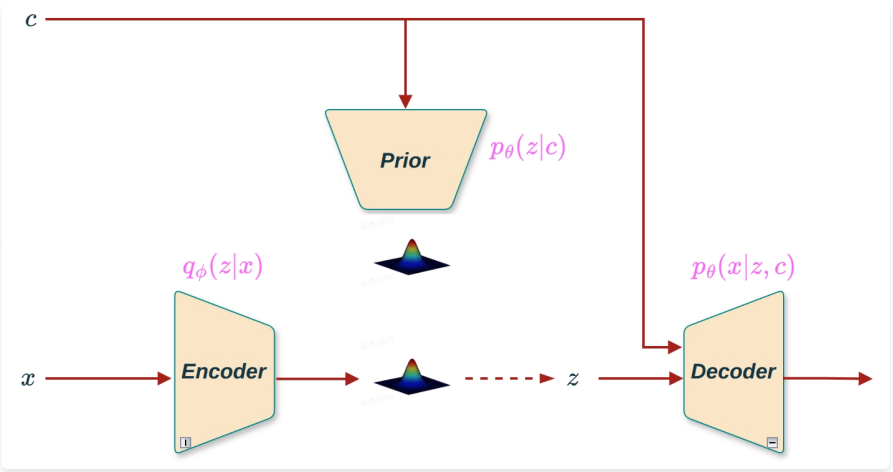


图9 条件只加在解码器的CVAE变体(c和z非独立的情况)

3.4 变体3:条件只加在编码器?

理论问题: 果条件 c 只加在编码器，即 $q_\phi(z|x,c)$，而解码器不使用条件，即 $p_\theta(x|z)$，会出现什么问题?

问题分析:

生成过程不可控: - 在生成新样本时，我们需要从先验 $p(z|c)$ 或 $p(z)$ 采样 z，然后通过解码器 $p_\theta(x|z)$ 生成 x - 由于解码器不依赖于条件 c，无法根据条件控制生成内容 - 即使条件影响编码过程，生成时也无法利用条件信息

结论:条件至少要在解码器中使用，才能实现条件生成。因此，CVAE的标准形式是条件同时加在编码器和解码器，或者只加在解码器。

---

4. Conditional的作用与本质

4.1 Conditional的作用

在CVAE中，条件变量 c 起到以下关键作用:

1. **控制生成内容**:
   - 通过指定不同的条件 c，可以生成不同类别的样本
   - 例 :在MNIST上，c 可以是数字标签（0-9），生成对应数字的图像
2. **正则化潜在空间**:
   - 条件先验 $p(z|c)$ 为不同条件提供不同的先验分布
   - 有助于在潜在空间中组织不同类别的表示

4.2 Conditional的本质:改变潜变量z的分布

核心思想:CVAE中条件 c 的本质作用是**改变潜在变量 z 的分布**。

4.2.1 VAE中的z分布

在VAE中，潜在变量 z 的先验分布是固定的:

$$p(z) = \mathcal{N}(0, I) \tag{12}$$

无论生成什么内容，z 都从相同的标准正态分布采样。

4.2.2 CVAE中的z分布变化

在CVAE中，条件 c 改变了 z 的分布:

非独立情况为例 - 先验 $p_\theta(z|c)$ 直接依赖于条件 c - 不同条件 c 对应不同的先验分布: $\mathcal{N}(\mu_{prior}(c), \sigma^2_{prior}(c))$ - 后验 $q_\phi(z|x,c)$ 也依赖于条件 c - 条件 c 直接改变了潜在变量 z 的分布

4.2.3 数学表达

VAE:

$$z \sim p(z) = \mathcal{N}(0, I) \tag{13}$$

潜在变量 z 服从固定的标准正态分布。

CVAE（非独立情况）:

$$z \sim p_\theta(z|c) = \mathcal{N}(\mu_{prior}(c), \sigma^2_{prior}(c)) \tag{14}$$

先验分布直接依赖于条件 c，不同条件对应不同的分布。

4.3 总结

CVAE的核心机制: 1. **条件编码**:将条件 c 编码为数值向量（one-hot 或 embedding） 2. **条件注入**:将条件 c 注入到编码器和/或解码器中 3. **分布改变**:条件 c 改变潜在变量 z 的分布（先验和/或后验） 4. **条件生成**:通过从条件相关的分布采样 z，生成条件相关的样本

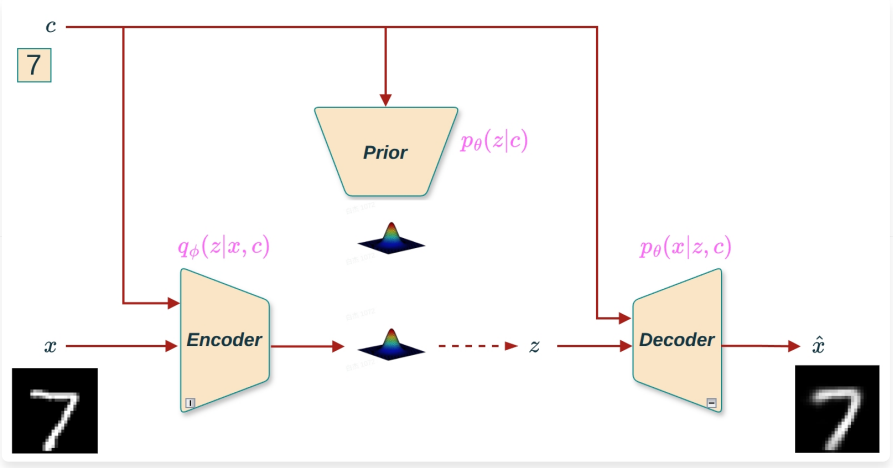


图10 CVAE的完整架构图

参考文献

1. Sohn, K., Lee, H., & Yan, X. (2015). Learning structured output representation using deep conditional generative models. *Advances in neural information processing systems*, 28.
2. Kingma, D. P., & Welling, M. (2013). Auto-encoding variational bayes. *arXiv preprint arXiv:1312.6114*.
3. 《深度学习5:生成模型》
4. Conditional Variational Autoencoders