GAN系列篇-01.GAN理论篇: 从“对抗训练”到“生成模型”

1. GAN的概述

1.1 GAN 是什么?

GAN（Generative Adversarial Network，生成对抗网络）由三个关键词组成:

- **Generative**（生成式）:目标是学习真实数据 $p_{data}(x)$ 的分布，并能从中采样生成新的、逼真的数据。
- **Adversarial**（对抗式）:通过引入一个“对手”（判别器 D）来训练生成器（G），形成一种博弈关系。
- **Networks**（网络）:生成器 G 和判别器 D 都由神经网络实现，通过反向传播和随机梯度下降 (SGD) 进行优化。

核心机制:

1. **生成器**（Generator, G）:接收一个简单的随机噪声向量 z（通常来自标准正态分布或均匀分布），并将其映射为一个看起来像真实数据的样本 $x' = G(z)$。它的目标是“以假乱真”。
2. **判别器**（Discriminator, D）:接收一个数据样本（可能是真实的 $x \sim p_{data}$，也可能是生成的 $x' = G(z)$），并输出一个概率值，表示该样本是真实数据的可能性。它的目标是“火眼金睛”，准确区分真假。

这两个网络在训练过程中相互对抗、共同进化:

- **D 的训练**:在 G 固定的情况下，D 被训练得越来越好，能更准确地分辨出 G 生成的假样本。
- **G 的训练**:在 D 固定的情况下，G 被训练得越来越好，能生成让当前 D 误判为真实的假样本。

这个过程就是一个**极小-极大**（min-max）的优化问题。

1.2 与 VAE 的对比:为什么需要 GAN?

为了更好地理解 GAN 的动机，我们先回顾一下变分自编码器 (VAE) 的局限性。

VAE 的局限性:

- VAE 使用重构损失（ L2 或交叉熵）。这种损失函数隐含了一个很强的假设:数据的各个维度（例 图像的每个像素）是独立同分布的。
- 对于高维复杂数据（ 自然图像），像素之间存在强烈的依赖关系，这个假设显然不成立。这导致 VAE 生成的图像往往比较模糊，缺乏高频细节和锐利的纹理。

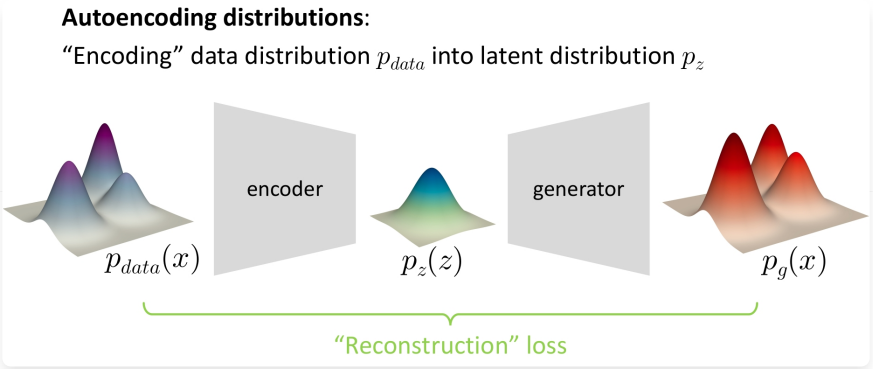


图1 VAE 的架构图

GAN 的优势:

- GAN 不直接计算逐像素的误差，而是通过判别器 D 来学习一个整体的、感知层面的损失函数。
- 判别器 D 作为一个可学习的"裁判"，能够捕捉到数据分布中复杂的、全局的结构和模式。只要生成的图像在整体上"看起来真实"，即使某些像素点有偏差，D 也可能给出高分。
- 因此，GAN 通常能生成更清晰、更逼真的图像。

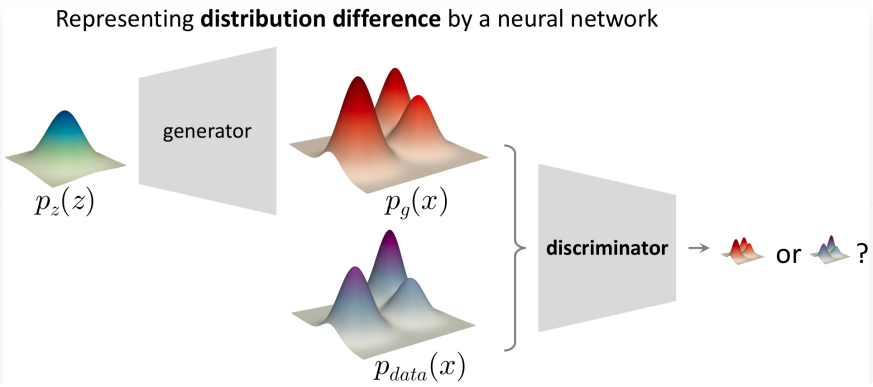


图2 GAN 生成结果对比

形象比喻:

- **VAE** 像是一个临摹者，老师（重构损失）会逐笔指出他画错了哪里（哪个像素不对），但他可能只学会了模仿局部，而没掌握整体神韵。
- **GAN** 像是一个造假者，他有一个专门鉴定真伪的专家（判别器 D）在不断挑战他。造假者必须从整体风格、质感等宏观层面去模仿，才能骗过专家，因此他的作品往往更具“灵魂”。

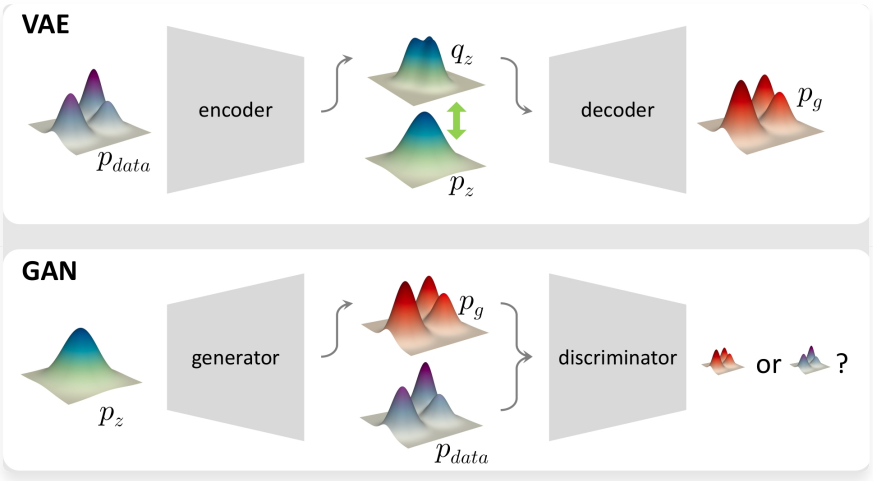


图3 VAE 和 GAN 的框架对比图

1.3 GAN 的网络设计图

GAN 的训练过程包含两个关键步骤:

生成部分:

通过先验分布 $z \sim p(z)$ 采样噪声向量，送入生成网络 G，生成一个假图片 $x' = G(z)$，然后送入判别网络 D，被判别为假（输出接近 0）。

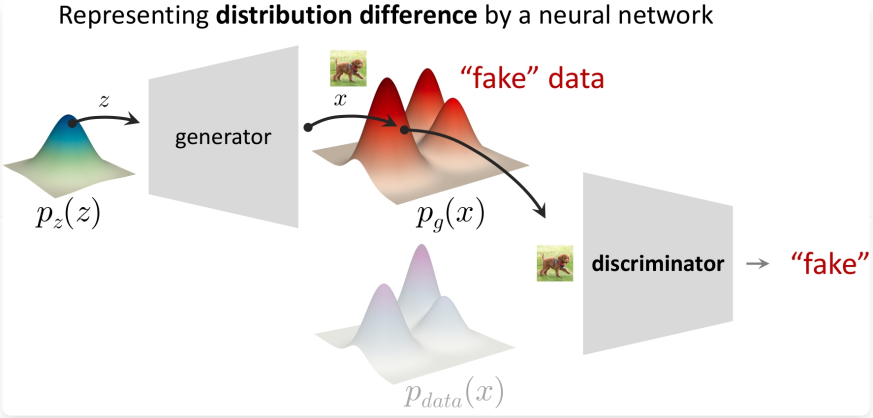


图4 GAN 生成部分示意图

对抗部分:

从真实数据集 $x \sim p_{data}(x)$ 采样的真实图片，送入判别网络 D，被判别为真（输出接近 1）。

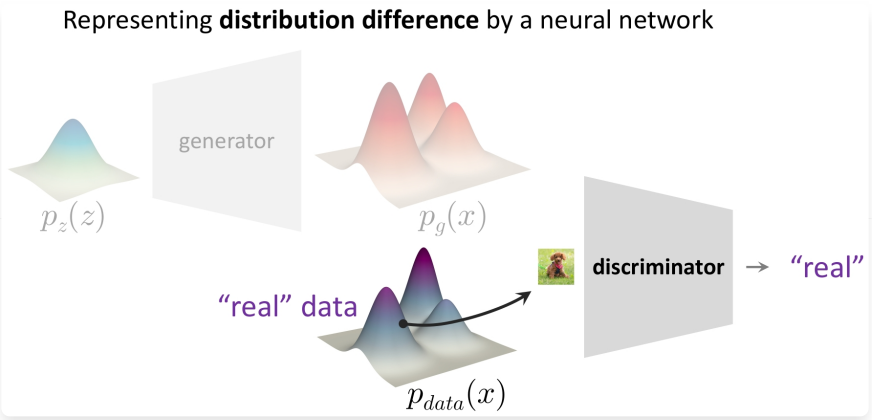


图5 GAN 对抗部分示意图

---

2. GAN 的数学原理与理论结果

这里先给出论文（Goodfellow et al., 2014）中 GAN 的经典目标函数:

$$\min_G \max_D L(D,G) = \mathbb{E}_{x\sim p_{data}}[\log D(x)] + \mathbb{E}_{z\sim p_z}[\log(1-D(G(z)))] \quad (1)$$

这个公式完美体现了 min-max 博弈: * $\max_D$:判别器 D 希望最大化这个值。它希望对真实数据 x 输出接近 1（$\log D(x)$ 趋近于 0），对生成数据 $G(z)$ 输出接近 0（$\log(1-D(G(z)))$ 也趋近于 0）。 * $\min_G$:生成器 G 希望最小化这个值。由于第二项是负的，所以 G 实际上是在最大化 $\mathbb{E}[\log D(G(z))]$，即努力让 D 认为它的假样本是真实的。

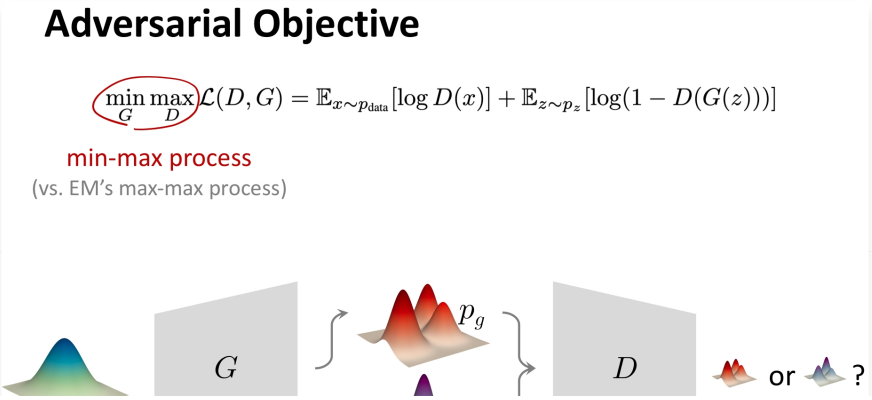




图6 GAN 的 Loss 图

接下来，我们看看在训练过程中这个目标函数是怎么发挥作用的。

2.1 D-step

在这个过程中，我们冻结生成网络 G，优化对抗网络 D，于是公式(1)就变成了

$$\begin{aligned}\max_D L(D) &= \mathbb{E}_{x\sim p_{data}}[\log D(x)] + \mathbb{E}_{z\sim p_z}[\log(1-D(G(z)))] \\ &= \mathbb{E}_{x\sim p_{data}}[\log D(x)] + \mathbb{E}_{x\sim p_g}[\log(1-D(x))]\end{aligned} \tag{2}$$

即:此时目标函数（对抗网络）为一个分类器，于是可以使用 BCE（Binary Cross Entropy）来描述。

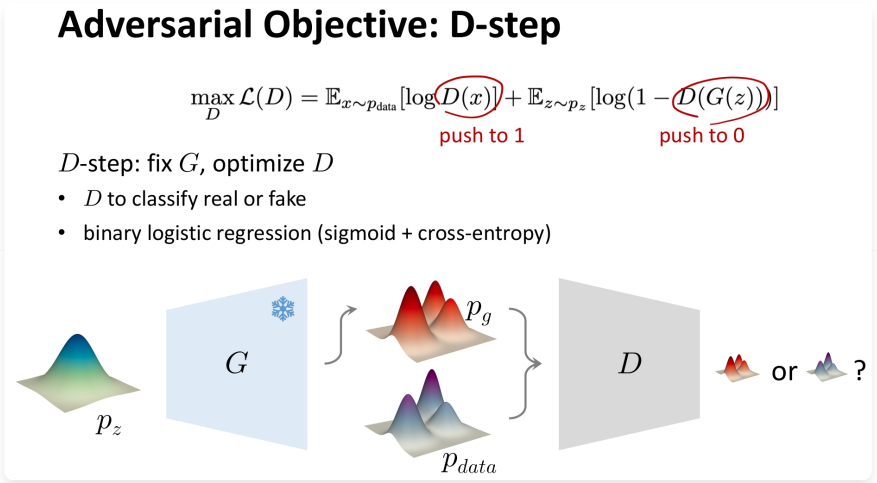


图7 冻结生成网络 G 的 Loss 图

2.2 G-step

在这个过程中，我们冻结对抗网络 D，优化生成网络 G，于是公式(1)就变成了

$$\min_G L(G) = \mathbb{E}_{z\sim p_z}[\log(1-D(G(z)))] \tag{3}$$

即:此时目标函数（生成网络）的目标是生成假图片，让对抗网络 D 误以为真，于是可以使用最大似然估计来描述。



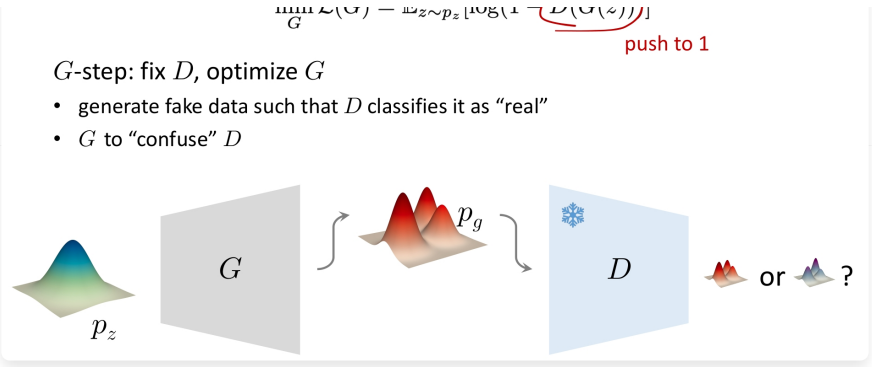


图8 冻结对抗网络 D 的 Loss 图

---

3. GAN的详细推导

给定真实数据分布 $p_{\text{data}}(x)$，我们希望训练一个生成器 G，使其诱导的分布 $p_g(x)$ 尽可能接近 $p_{\text{data}}(x)$。

GAN 通过引入一个判别器 D，将这个问题转化为一个极小极大博弈（minimax game）：

$$\min_G \max_D L(D, G)$$

通过详细的推导，我们可以得到三个有用的结论。

3.1 构建二分类问题 → 推导损失函数

设定

- **真实样本**: $x \sim p_{\text{data}}(x)$，标签为 1
- **生成样本**: $x = G(z), z \sim p_z(z)$，其分布记为 $p_g(x)$，标签为 0
- **判别器**: $D(x) \in [0, 1]$ 输出"x 是真实样本"的概率

使用最大似然估计（MLE）

我们希望 $D(x)$ 能正确区分真假样本。对数似然为:

$$\mathcal{L}(D) = \mathbb{E}_{x \sim p_{\text{data}}}[\log D(x)] + \mathbb{E}_{x \sim p_g}[\log(1 - D(x))]$$

这正是标准的二分类交叉熵损失的负值（因为 MLE 要最大化似然）。

因此，**判别器的目标是最大化该式**。

而生成器希望让判别器犯错，即让 $D(G(z))$ 接近 1，等价于最小化 $\mathbb{E}_z[\log(1 - D(G(z)))]$。

于是，整个博弈的目标函数为:

$$\min_G \max_D L(D, G) = \mathbb{E}_{x \sim p_{\text{data}}}[\log D(x)] + \mathbb{E}_{z \sim p_z}[\log(1 - D(G(z)))]$$

这就是 GAN 的原始损失函数（minimax 形式）。

3.2 求最优判别器 $D^*(x)$（固定 G）

我们现在固定生成器 G（即固定 p_g），求使 $L(D, G)$ 最大的判别器 D^*。

将期望写成积分形式:

$$L(D, G) = \int_x p_{\text{data}}(x) log D(x)\, dx + \int_x p_g(x) log(1 - D(x))\, dx$$

由于积分是对每个 x 独立的，我们可以对每个 x 单独最大化被积函数:

$$f(D) = p_{\text{data}}(x) \log D + p_g(x) \log(1 - D)$$

对 D 求导（注意 $D = D(x)$ 是标量）:

$$\frac{df}{dD} = \frac{p_{\text{data}}(x)}{D} - \frac{p_g(x)}{1 - D}$$

令导数为 0:

$$\frac{p_{\text{data}}(x)}{D} = \frac{p_g(x)}{1 - D}$$

$$\Rightarrow p_{\text{data}}(x)(1 - D) = p_g(x) D$$

$$\Rightarrow p_{\text{data}}(x) = D\left(p_{\text{data}}(x) + p_g(x)\right)$$

解得:

$$D^*(x) = \frac{p_{\text{data}}(x)}{p_{\text{data}}(x) + p_g(x)} \tag{4}$$

> ✅ **结论1**:对于任意给定的生成网络 G，其最优的对抗网络 D 为公式(4)。

Theoretical Results

1. For any given G, the optimal D is:

$$D_G^*(x) = \frac{p_{\text{data}}(x)}{p_{\text{data}}(x) + p_g(x)}$$

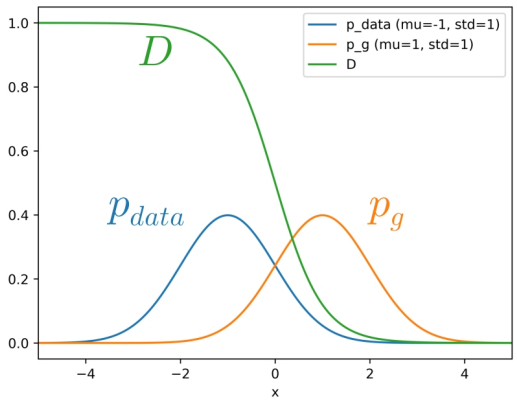


图9 最优判别器示意图

3.3 将 D^* 代入 $L(D,G)$，得到散度形式

将 $D^*(x)$ 代回目标函数:

$$L(D^*, G) = \mathbb{E}_{p_{\text{data}}}\left[\log \frac{p_{\text{data}}(x)}{p_{\text{data}}(x) + p_g(x)}\right] + \mathbb{E}_{p_g}\left[\log \frac{p_g(x)}{p_{\text{data}}(x) + p_g(x)}\right]$$

我们引入中间分布:

$$m(x) = \frac{p_{\text{data}}(x) + p_g(x)}{2}$$

注意到:

$$\frac{p_{\text{data}}(x)}{p_{\text{data}}(x) + p_g(x)} = \frac{1}{2} \cdot \frac{p_{\text{data}}(x)}{m(x)}, \quad \frac{p_g(x)}{p_{\text{data}}(x) + p_g(x)} = \frac{1}{2} \cdot \frac{p_g(x)}{m(x)}$$

因此，

$$
\begin{aligned}
L(D^*, G) &= \mathbb{E}_{p_{\text{data}}}\left[\log\left(\frac{1}{2}\cdot\frac{p_{\text{data}}}{m}\right)\right] + \mathbb{E}_{p_g}\left[\log\left(\frac{1}{2}\cdot\frac{p_g}{m}\right)\right] \\
&= \mathbb{E}_{p_{\text{data}}}\left[\log\frac{p_{\text{data}}}{m} - \log 2\right] + \mathbb{E}_{p_g}\left[\log\frac{p_g}{m} - \log 2\right] \\
&= \underbrace{\int p_{\text{data}} \log\frac{p_{\text{data}}}{m} dx}_{\text{KL}(p_{\text{data}}||m)} + \underbrace{\int p_g \log\frac{p_g}{m} dx}_{\text{KL}(p_g||m)} - 2\log 2 \\
&= 2\cdot\underbrace{\left(\frac{1}{2}\text{KL}(p_{\text{data}}||m) + \frac{1}{2}\text{KL}(p_g||m)\right)}_{\text{JS}(p_{\text{data}}||p_g)} - 2\log 2
\end{aligned}
$$

即:

$$
L(D^*, G) = 2\cdot\text{JS}(p_{\text{data}}||p_g) - 2\log 2 \tag{5}
$$

> ✅ **结论2**:在最优判别器 D^* 的情况下，GAN 的目标函数为公式(5)，即 GAN 优化目标为 JS 散度。

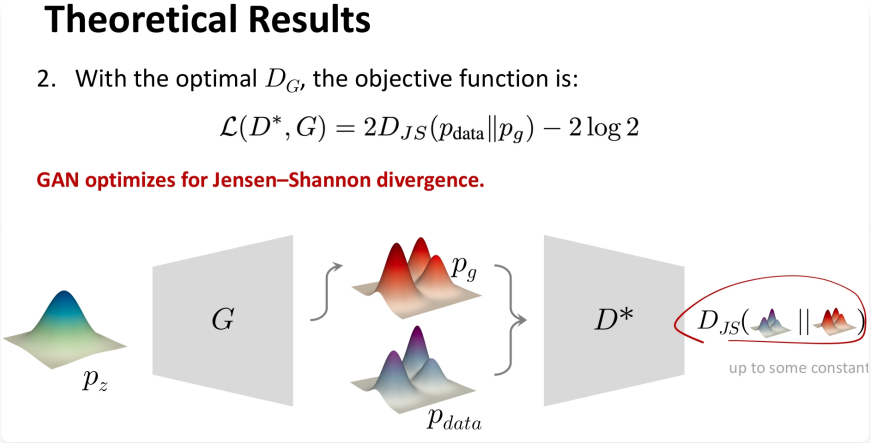


图10 JS 散度示意图

其中 **Jensen-Shannon 散度（JS 散度）** 定义为:

$$
\text{JS}(P||Q) = \frac{1}{2}\text{KL}\left(P\,||\,\frac{P+Q}{2}\right) + \frac{1}{2}\text{KL}\left(Q\,||\,\frac{P+Q}{2}\right)
$$

JS 散度的特点:

- D_{JS} 是对称的，D_{KL} 不是对称的
- D_{JS} 是有边界的 $[0, \log 2]$，D_{KL} 没有边界 $[0, +\infty)$

- D_{JS} 更加稳定

3.4 求最优生成器 G^*

现在我们最小化 $L(D^*, G)$ 关于 G（即关于 p_g）：

$$\min_G L(D^*, G) = \min_{p_g} \left[2 \cdot \mathrm{JS}(p_{\text{data}} || p_g) - 2\log 2\right]$$

由于 $-2\log 2$ 是常数，等价于:

$$\min_{p_g} \mathrm{JS}(p_{\text{data}} || p_g)$$

而 JS 散度具有以下性质: - $\mathrm{JS}(P||Q) \geq 0$ - $\mathrm{JS}(P||Q) = 0$ 当且仅当 $P = Q$（几乎处处相等）

因此，全局最小值在 $p_g = p_{\text{data}}$ 时取得，此时:

$$D^*(x) = \frac{p_{\text{data}}(x)}{p_{\text{data}}(x) + p_{\text{data}}(x)} = \frac{1}{2}$$

即:

$$L(D^*, G^*) = 2 \cdot 0 - 2\log 2 = -2\log 2 \tag{6}$$

> ✅ **结论3**:全局最优解在 $p_g = p_{\text{data}}$ 时得到，结果为公式(6)。

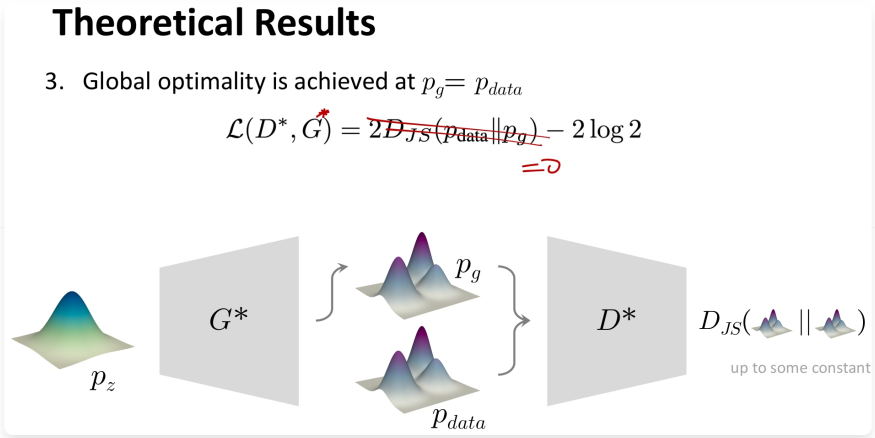


图11 最优生成器的Loss:展示了当 $p_g = p_{\text{data}}$ 时，GAN达到全局最优，损失函数值为 $-2\log 2$

最终，我们将三个结论汇总在一起， 图11所示:

Theoretical Results: Summary

1. For any given G, the optimal D is:

$$D_G^*(x) = \frac{p_{\text{data}}(x)}{p_{\text{data}}(x) + p_g(x)}$$

2. With optimal D_G, GAN optimizes for Jensen–Shannon divergence:

$$\mathcal{L}(D^*, G) = 2D_{JS}(p_{\text{data}} \| p_g) - 2\log 2$$

3. Global optimality is achieved at $p_g = p_{data}$

$$\mathcal{L}(D^*, G^*) = -2\log 2$$

图12 GAN 三个重要的理论总结

📚 参考

- Goodfellow et al., *Generative Adversarial Nets*, NeurIPS 2014.
- Arjovsky & Bottou, *Towards Principled Methods for Training Generative Adversarial Networks*, 2017.
- Kaiming He, Deep Generative Models.