GAN系列篇-03.CGAN理论篇: 从“无条件生成”到“条件生成”

1. GAN的问题与CGAN的引入

1.1 GAN的局限性

生成对抗网络（GAN）是一种强大的生成模型，它通过对抗训练让生成分布 $p_g(x)$ 逼近真实数据分布 $p_{data}(x)$，从而能够生成逼真的样本。标准GAN从随机噪声 $z \sim p_z(z)$ 生成样本，通过生成器 $G(z)$ 学习到的分布 $p_g(x)$ 来生成新样本。

然而，传统的GAN在处理一些需要特定条件控制的生成任务时显得力不从心。具体来说:

无法控制生成内容:标准GAN从随机噪声 $z \sim p_z(z)$ 生成样本，生成的内容是完全随机的，无法指定生成特定类别的样本。例 ，在MNIST数据集上，我们无法控制生成器生成数字“7”的图像，只能随机生成任意数字。

1.2 CGAN的解决方案

在图像生成任务中，我们可能希望根据特定标签（ 数字“7”）来生成相应的图像，而不是随机生成一个图像。

为了增强GAN的灵活性和可控性，提出了**条件生成对抗网络（Conditional Generative Adversarial Network, CGAN）**。CGAN允许我们在生成过程中加入额外的信息（条件），从而实现更加精确和可控的数据生成。

核心思想:在GAN的基础上，引入条件变量 c，使得生成过程依赖于条件信息。通过指定条件变量 c（ 类别标签、文本描述等）来指导模型生成特定类别的样本。

为了更好地理解GAN和CGAN的区别，我们先回顾一下标准GAN的架构:

标准GAN: - 生成器:$G(z) \rightarrow x$，输入随机噪声 z，输出样本 x - 判别器:$D(x) \rightarrow [0,1]$，输入样本 x，输出真实概率

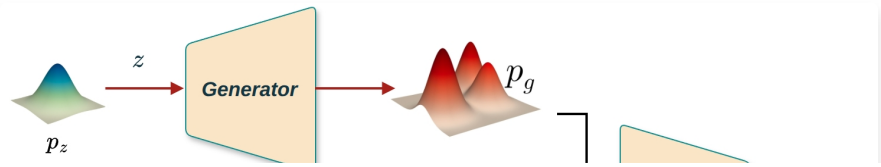




图1 标准GAN的框架图:生成器从噪声 z 生成样本 x，判别器判断样本 x 是否真实

---

2. CGAN的核心问题

2.1 问题1:条件c如何加入模型?

在CGAN中，条件变量 c 需要同时加入到生成器和判别器中，形成条件对抗。

生成器 $G(z|c)$: - 输入:噪声 $z \sim p_z(z)$ + 条件 c - 输出:以 c 为条件的假样本 $x' = G(z|c)$ - 目标:生成符合条件 c 的逼真样本

判别器 $D(x|c)$: - 输入:样本 x + 条件 c - 输出:该样本在给定条件 c 下为真实的概率 $D(x|c) \in [0,1]$ - 目标:判断 (x,c) 是否匹配（即 x 是否属于类别 c）

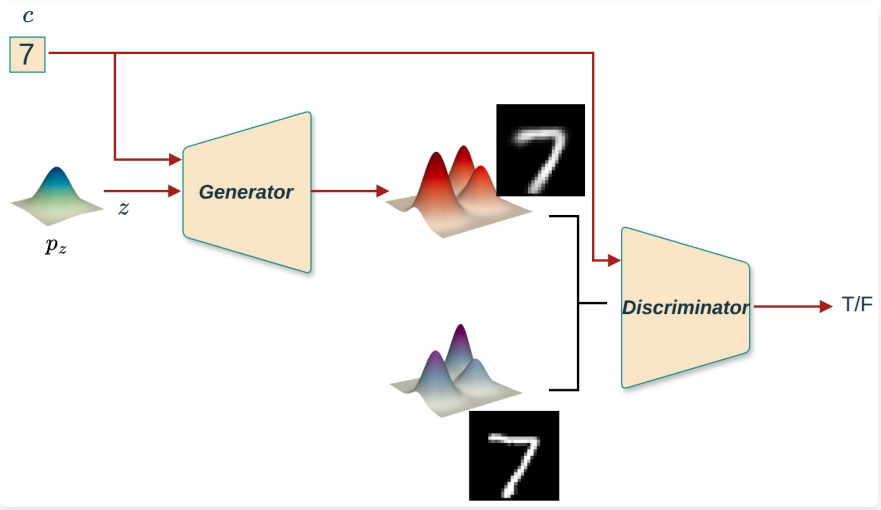


图2 CGAN的框架图:生成器从噪声 z 和条件 c 生成样本 x，判别器判断样本 x 在给定条件 c 下是否真实

✅ **关键:G 和 D 都"知道"当前的条件** c，形成条件对抗。这与标准GAN的区别在于，判别器不仅要判断样本是否真实，还要判断样本是否与条件匹配。

2.2 问题2:条件c如何编码?

条件变量 c 通常是离散标签（ MNIST 的 0~9），需要转换为数值向量才能输入神经网络。常见的编码方式有:

方式1:One-Hot编码（最常用） - 方法:将类别索引转换为独热向量 - 例 :类别3 →

$[0, 0, 0, 1, 0, 0, 0, 0, 0, 0]$（MNIST的10个类别） - 优点:简单直观，不需要额外参数 - 缺点:维度等于类别数，当类别数很大时维度很高；编码是固定的，无法学习

方式2:Embedding编码 - 方法:使用可学习的嵌入层将类别索引映射为低维向量 - 例 :类别3 → 可学习的N维向量 - 优点:维度可自定义，通常比one-hot更紧凑；可以学习到类别之间的语义关系 - 缺点:需要额外的可学习参数

实现示例（MNIST, 10类，One-Hot编码）:

```
# 生成器输入
z = torch.randn(batch_size, latent_dim)          # [B, 100]
c = F.one_hot(labels, num_classes=10).float()    # [B, 10]
input_g = torch.cat([z, c], dim=1)               # [B, 110]
x_fake = G(input_g)

# 判别器输入
x_flat = x.view(batch_size, -1)                   # [B, 784]
input_d = torch.cat([x_flat, c], dim=1)          # [B, 794]
output = D(input_d)                               # [B, 1]
```

---

3. CGAN的损失函数推导

3.1 从条件概率建模出发

CGAN的核心是将无条件生成问题转化为条件生成问题。现在的问题变成:给定条件 c，判断 x 是来自真实条件分布 $p_{data}(x|c)$ 还是生成分布 $p_g(x|c)$。

3.2 判别器的目标

判别器要最大化以下对数似然:

$$L_D = \mathbb{E}_{x \sim p_{data}(x|c)} [\log D(x|c)] + \mathbb{E}_{z \sim p_z(z)} [\log (1 - D(G(z|c)|c))]$$

其中:

- **第一项**:真实样本对 (x, c) 应被判为真（输出 ≈ 1），这里 $(x, c) \sim p_{data}(x, c)$ 表示从数据集中采样 (x, c) 对
- **第二项**:生成样本对 $(G(z|c), c)$ 应被判为假（输出 ≈ 0），这里 $(x, c) \sim p_{data}(x, c)$（从数据集中采样条件 c），$z \sim p_z(z)$（从先验分布采样噪声），$G(z|c) \sim p_g(x|c)$（生成器输出）

📌 **注意**:在训练时，我们从数据集中采样 (x, c) 对，条件 c 自然来自数据分布。判别器不仅要判

断样本是否真实，还要判断样本是否与条件匹配。

3.3 生成器的目标

生成器希望欺骗判别器，即让 $D(G(z|c)|c)$ 尽可能大。

原始目标（理论形式）：

$$\min_G \mathbb{E}_{z\sim p_z(z)} \left[\log\left(1 - D(G(z|c)|c)\right)\right]$$

实践中采用非饱和版本（避免梯度消失）：

$$\max_G \mathbb{E}_{z\sim p_z(z)} \left[\log D(G(z|c)|c)\right]$$

这与标准GAN中生成器的非饱和损失形式一致，在训练早期能提供更强的梯度信号。

3.4 完整的Min-Max目标函数

将两者结合，得到CGAN的标准损失函数:

$$\min_G \max_D L(D,G) = \mathbb{E}_{x\sim p_{data}(x|c)} \left[\log D(x|c)\right] + \mathbb{E}_{z\sim p_z(z)} \left[\log\left(1 - D(G(z|c)|c)\right)\right] \quad (1)$$

- **对比标准GAN**:只是在 D 和 G 的输入中**显式加入了条件** c，并将所有分布条件化!

标准GAN的目标函数:

$$\min_G \max_D L(D,G) = \mathbb{E}_{x\sim p_{data}(x)} \left[\log D(x)\right] + \mathbb{E}_{z\sim p_z(z)} \left[\log\left(1 - D(G(z))\right)\right]$$

CGAN的目标函数:

$$\min_G \max_D L(D,G) = \mathbb{E}_{x\sim p_{data}(x|c)} \left[\log D(x|c)\right] + \mathbb{E}_{z\sim p_z(z)} \left[\log\left(1 - D(G(z|c)|c)\right)\right]$$

可以看出，CGAN只是在标准GAN的基础上，将所有分布都条件化于 c:$p_{data}(x) \to p_{data}(x|c)$，$p_g(x) \to p_g(x|c)$。

---

4. 理论解释:与条件JS散度的关系

4.1 最优判别器

类似标准GAN，可以证明当判别器最优时:

$$D^*(x|c) = \frac{p_{data}(x|c)}{p_{data}(x|c) + p_g(x|c)}$$

这个结果与标准GAN类似，只是将无条件分布替换为条件分布。判别器输出的是:给定条件 c，样本 x 来自真实条件分布 $p_{data}(x|c)$ 的概率。

4.2 条件JS散度

将最优判别器代入目标函数后，可得:

$$L(D^*, G) = 2\text{JS}\left(p_{data}(x|c) \| p_g(x|c)\right) - 2\log 2$$

📌 **结论**:CGAN的训练等价于最小化条件分布 $p_g(x|c)$ 与真实条件分布 $p_{data}(x|c)$ 之间的**期望JS散度**。

当对所有条件 c 都有 $p_g(x|c) = p_{data}(x|c)$ 时，达到全局最优。

---

5. Conditional的作用与本质

5.1 Conditional的作用

在CGAN中，条件变量 c 起到以下关键作用:

1. **控制生成内容**:
   - 通过指定不同的条件 c，可以生成不同类别的样本
   - 例 :在MNIST上，c 可以是数字标签（0-9），生成对应数字的图像
2. **增强判别能力**:
   - 判别器不仅要判断样本是否真实，还要判断样本是否与条件匹配
   - 这有助于生成器学习生成与条件一致的样本
3. **提高训练稳定性**:
   - 条件信息为生成器和判别器提供了额外的监督信号
   - 有助于避免mode collapse问题

5.2 Conditional的本质:条件对抗

核心思想:CGAN中条件 c 的本质作用是**将无条件对抗转化为条件对抗**。

5.2.1 标准GAN中的对抗

在标准GAN中: - 生成器:$G(z) \to x$，从噪声生成样本 - 判别器:$D(x) \to [0,1]$，判断样本是否真实 - 对抗:生成器试图生成逼真样本，判别器试图区分真假

5.2.2 CGAN中的条件对抗

在CGAN中: - 生成器:$G(z|c) \to x$，从噪声和条件生成样本 - 判别器:$D(x|c) \to [0,1]$，判断样本在给定条件下是否真实 - 条件对抗:生成器试图生成与条件匹配的逼真样本，判别器试图判断样本是否真实且与条件匹配

5.2.3 数学表达

标准GAN:

$$\min_G \max_D L(D,G) = \mathbb{E}_{x \sim p_{data}(x)}[\log D(x)] + \mathbb{E}_{z \sim p_z(z)}[\log(1 - D(G(z)))]$$

CGAN:

$$\min_G \max_D L(D,G) = \mathbb{E}_{x \sim p_{data}(x|c)}[\log D(x|c)] + \mathbb{E}_{z \sim p_z(z)}[\log(1 - D(G(z|c)|c))]$$

条件 c 将无条件分布 $p(x)$ 分解为条件分布 $p(x|c)$，使得生成过程可控。

📚 参考

- Mirza, M., & Osindero, S. (2014). Conditional generative adversarial nets. *arXiv preprint arXiv:1411.1784*.
- Goodfellow et al., *Generative Adversarial Nets*, NeurIPS 2014.