机器学习篇-01.生成模型基础

1. 什么是生成模型

1.1 生成模型的定义

生成模型（Generative Model）的目标是对给定数据 x 的概率分布 p(x) 进行建模（用数学式来表示），然后生成新的模拟数据，这些数据就像是从该群体中选出来的一样。

例 ，我们可以将某个群体的身高的概率分布表示为正态分布，这是一个很好的生成模型。图1中的图形是一个均值为 172.7，标准差为 4.8 的正态分布。对这样的群体的特征进行建模就是生成模型的目标。

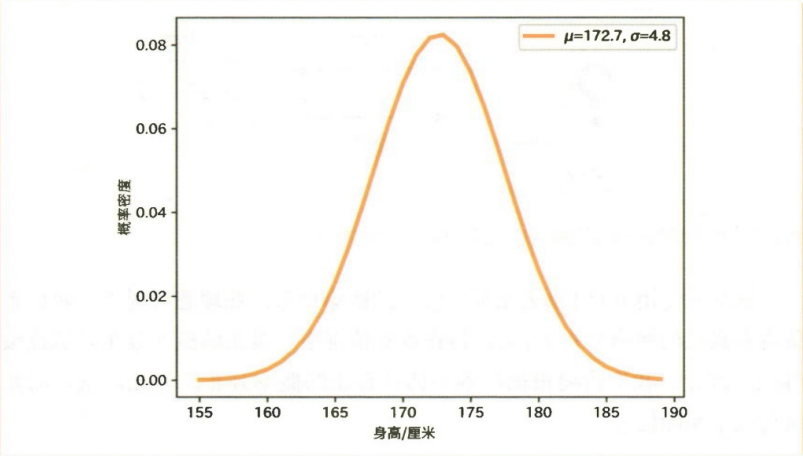


图1 基于正态分布的生成模型的示例

1.2 总体和样本

总体（Population）一词主要用于统计学。总体指的是对象的整体。通常，总体的规模是巨大的。统计学的目标之一就是利用数量有限的样本对总体进行“估计”。

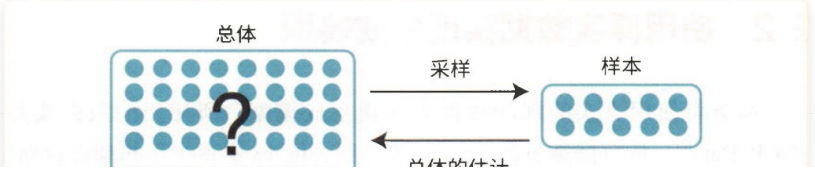




图2 总体和样本的关系

生成模型中的总体和样本

生成模型也是利用样本对总体进行估计。在生成模型的语境下，总体就是样本背后的概率分布。这种概率分布称为“真正的概率分布”或“总体分布”。

图3使用 $p^*(x)$ 来表示样本服从的概率分布。在理想情况下，我们希望得到真正的概率分布 $p^*(x)$，但在现实情况下，真正的概率分布无法直接得知。因此，我们需要根据样本来估计真正的概率分布。

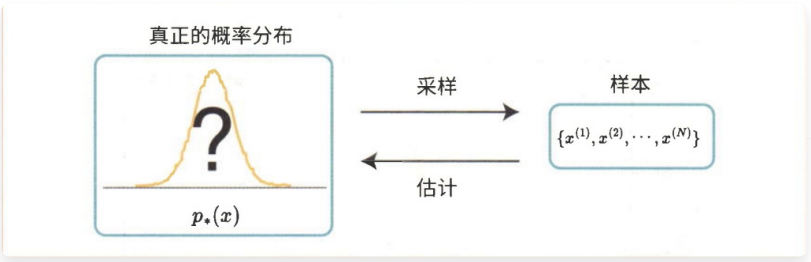


图3 生成模型中真正的概率分布与样本之间的关系

创建生成模型的两项任务

为此，通常需要执行以下两项任务:

1. **建模（Modeling）**:假定真正的概率分布近似于参数可调整的概率分布。
2. **参数估计（Parameter Estimation）**:估计参数，使概率分布拟合样本数据。

通过完成“建模”和“参数估计”这两项任务，我们就创建了一个生成模型。首先，在建模阶段，我们建立一个可由参数控制的概率分布，比　正态分布。然后，在参数估计阶段，我们会对参数进行调整，以使其最拟合样本。

---

2. 生成模型的核心概念

2.1 估计（Estimation）

估计是指根据观测到的样本数据，推断出概率分布的参数值。在生成模型中，我们需要估计模型的参数（例　，正态分布的均值 μ 和标准差 σ），使得模型能够最好地拟合观

测数据。

估计的目标是找到参数 θ，使得模型 $p(x;\theta)$ 能够最好地描述数据的分布特征。

2.2 生成（Generation）

生成是指使用训练好的生成模型来产生新的数据样本。一旦我们估计出了模型的参数，就可以使用这些参数来生成新的数据点，这些新数据应该具有与训练数据相似的特征。

生成过程通常涉及从学习到的概率分布中采样。

2.3 采样（Sampling）

采样是指从概率分布中随机抽取样本的过程。对于生成模型，采样是生成新数据的关键步骤。

- **直接采样**:对于简单的分布（ 正态分布），可以直接从分布中采样
- **间接采样**:对于复杂的分布，可能需要使用 MCMC、重要性采样等方法

---

3. 生成模型的参数估计方法

生成模型的参数估计主要有两种方法:

3.1 基于最大似然估计的方法

最大似然估计（Maximum Likelihood Estimation, MLE）是一种经典的参数估计方法。它的核心思想是:找到使观测数据出现概率最大的参数值。

特点: - 直接优化数据的似然函数 - 通常有解析解或可以通过梯度下降求解 - 适用于显式概率模型

典型应用: - 正态分布参数估计 - 多项式分布参数估计 - 自回归模型

3.2 基于潜变量的估计方法

基于潜变量的估计适用于包含隐变量（latent variables）的模型。这类模型假设观测数

据 x 是由隐变量 z 生成的，即:

$$p(x) = \int p(x|z)p(z)\,dz$$

特点: - 模型包含不可观测的隐变量 - 需要同时估计模型参数和推断隐变量 - 通常使用变分推断或 EM 算法

典型应用: - 高斯混合模型（GMM） - 变分自编码器（VAE） - 扩散模型

---

4. 概率分布的基本操作

4.1 联合分布、条件分布和边缘分布

在处理概率分布时，我们需要理解三种基本关系:

4.1.1 乘积规则 (Product Rule)

任何联合分布都可以表示为一系列一维条件分布的乘积:

$$p(x, y, z) = p(x|y, z) \cdot p(y|z) \cdot p(z)$$

这个规则允许我们将复杂的多维分布分解为更简单的条件分布。

4.1.2 求和规则 (Sum Rule)

任何边缘分布都可以通过对联合分布进行积分（或求和）得到:

$$p(y) = \int p(x, y)\,dx$$

4.1.3 条件分布的定义

条件分布可以通过联合分布和边缘分布计算:

$$p(x|y) = \frac{p(x, y)}{p(y)}$$

4.2 实例应用

假设我们有一个三组变量的联合分布 $p(x, y, z)$: - 我们观察到变量 x - 我们想要预测变量 y - 变量 z 的值未知且与我们无关

何从 $p(x, y, z)$ 估计 $p(y|x)$?

解决方案:

$$p(y|x) = \frac{p(x, y)}{p(x)} = \frac{\int p(x, y, z)\, dz}{\int\int p(x, y, z)\, dz\, dy}$$

通过求和规则和乘积规则，我们可以从联合分布中获得任意的条件分布。

---

5. 贝叶斯定理

5.1 定理表述

贝叶斯定理（由乘积规则和求和规则推导而来）:

$$p(y|x) = \frac{p(x|y) \cdot p(y)}{p(x)} = \frac{p(x|y) \cdot p(y)}{\int p(x|y) \cdot p(y)\, dy}$$

5.2 核心思想

贝叶斯定理定义了当新信息到达时不确定性转换的规则:

$$\text{后验概率} = \frac{\text{似然} \times \text{先验}}{\text{证据}}$$

术语解释: - **先验 (Prior)** $p(y)$: 在观察到数据 x 之前，对 y 的信念 - **似然 (Likelihood)** $p(x|y)$: 给定 y 时观察到 x 的概率 - **后验 (Posterior)** $p(y|x)$: 观察到 x 后对 y 的更新信念 - **证据 (Evidence)** $p(x)$: 观察到的数据的边际概率（归一化常数）

---

6. 统计推断:频率主义 vs 贝叶斯主义

6.1 问题设定

给定独立同分布 (i.i.d.) 数据 $X = (x_1, \ldots, x_n)$，这些数据来自分布 $p(x|\theta)$，需要估计参数 θ。

6.2 频率主义框架 (Frequentist Framework)

最大似然估计 (Maximum Likelihood Estimation, MLE):

$$\theta_{ML} = \arg\max_{\theta} p(X|\theta) = \arg\max_{\theta} \prod_{i=1}^{n} p(x_i|\theta) = \arg\max_{\theta} \sum_{i=1}^{n} \log p(x_i|\theta)$$

特点: - 将参数 θ 视为固定但未知的值 - 通过最大化数据出现的概率来估计参数 - 不包含对参数不确定性的量化

6.3 贝叶斯框架 (Bayesian Framework)

贝叶斯推断:

$$p(\theta|X) = \frac{\prod_{i=1}^{n} p(x_i|\theta) \cdot p(\theta)}{\int \prod_{i=1}^{n} p(x_i|\theta) \cdot p(\theta)\, d\theta}$$

特点: - 将参数 θ 视为随机变量 - 通过先验分布 $p(\theta)$ 编码对参数的不确定性 - 后验分布 $p(\theta|X)$ 不仅提供点估计，还提供不确定性信息

6.4 两种框架的对比

特性	频率主义	贝叶斯主义
变量性质	随机变量和确定性变量	所有变量都是随机的
适用条件	$n \gg d$ (样本数远大于参数数)	适用于所有 n
参数估计	点估计	概率分布

重要观察: - 现代机器学习模型中可调参数的数量与训练数据的大小相当 - 频率主义框架是贝叶斯框架的极限情况:

$$\lim_{n/d\to\infty} p(\theta|x_1,\ldots,x_n) = \delta(\theta-\theta_{ML})$$

6.5 贝叶斯框架的优势

1. **先验知识的编码**:可以将先验知识或期望的解决方案属性编码到先验分布中
2. **正则化作用**:先验是一种正则化形式，有助于防止过拟合
3. **不确定性量化**:除了点估计，后验分布还包含估计不确定性的信息

重要说明:贝叶斯框架只是提供了另一种观点，它**并不**与频率主义框架矛盾或否定它。

6.6 实例:抛硬币问题

场景 1:少量数据

问题:估计硬币正面朝上的概率 θ
数据:2 次投掷，结果都是正面 (H, H)

频率主义方法: - 在所有实验中硬币都是正面朝上 - $\theta_{ML} = 1$ - 结论:硬币不公平，总是正面朝上

贝叶斯方法: - 使用先验分布（例　，假设硬币可能是公平的） - 后验分布会考虑先验信念和数据 - 即使观察到两次正面，后验分布仍会显示一定的不确定性

场景 2:大量数据

问题:估计硬币正面朝上的概率 θ
数据:1000 次投掷，489 次反面，511 次正面

两种方法: - 数据量足够大，符合我们的期望 - 两种框架都会得出相似的结论:硬币是公平的