补充系列篇-00.导读

本篇将 **AE、DM、GAN、AR** 系列篇的内容串联起来，帮助读者建立整体框架，并了解各系列之间的逻辑关系与推荐阅读顺序。行文按 **建模** → **训练** → **采样** → **改进** 这条主线展开，读者可依自身基础按需跳读或顺序阅读。

---

1. 生成模型是什么?

1.1 核心概念

生成模型是一种**学习并逼近真实数据背后概率分布**的模型。其核心思路是: 从有限样本中估计 $p(x)$，构建可学习的模型分布 $p_(x)$，从而能够**采样生成**新的、看似合理的数据（ 图像、文本、蛋白质结构等）。

带概率建模的生成模型（Generative Models with Probabilistic Modeling）的典型流程:

> 原始数据 → 真实数据分布 → 估计的数据分布 → 从估计分布中采样生成新数据

各步骤含义 下:

步骤	含义
原始数据	观测到的有限样本（ 一批猫的图片）
→ **真实数据分布**	用这些样本推断背后的真实概率分布 $p(x)$（我们并不知道它的形式）
→ **估计的数据分布**	用模型学出一个近似分布 $p_(x)$ 去逼近真实分布

步骤	含义
→ **从估计分布中采样生成新数据**	从学到的 $p_(x)$ 中采样，得到新的、类似真实数据但从未出现过的样本（ 新的猫的图片）

简言之: **观测数据** → **推断分布** → **学习近似分布** → **利用近似分布生成新数据**，这就是概率生成模型的核心逻辑。

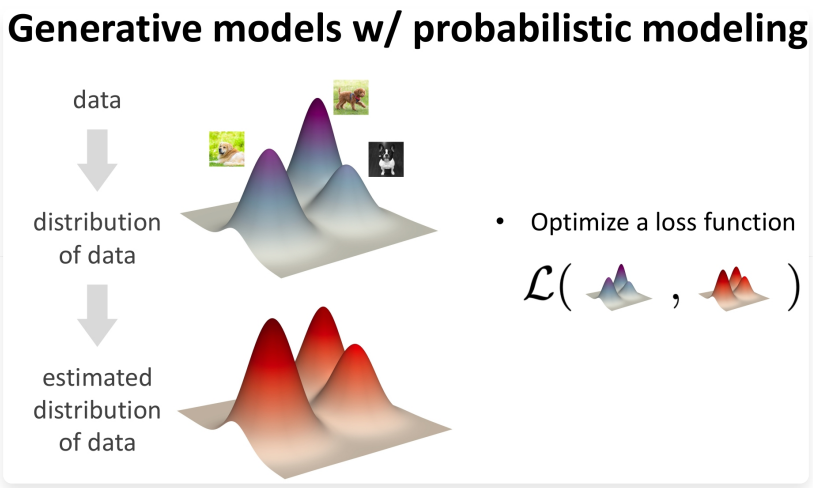


图1 学习过程: 使模型分布逼近数据分布

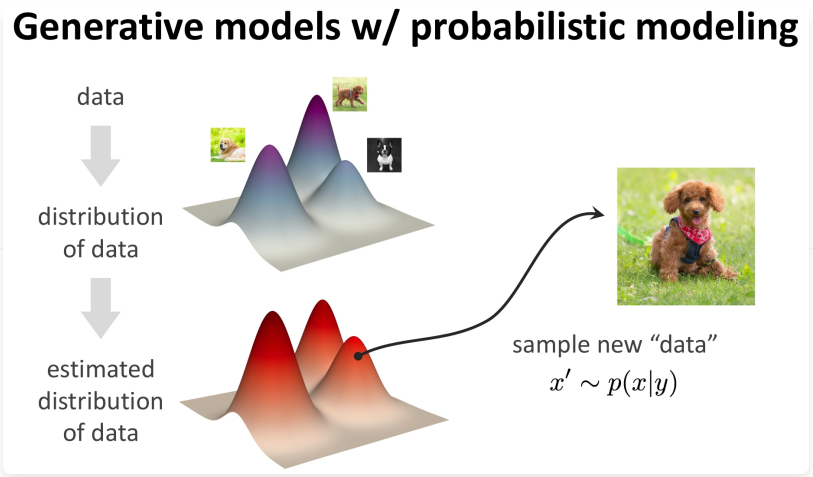


图2 采样过程: 从学到的分布中生成新样本

1.2 完整流程: 建模 → 训练 → 推理

一个深度生成模型系统通常包含以下四个阶段:

阶	英文	作用

段		
建模	Formulation	将现实问题转化为 $p(xy)$；将复杂分布分解为可处理的子问题（ 扩散过程、自回归因子分解）
表示	Representation	用深度网络（Transformer、UNet、MLP）参数化映射或条件分布
训练	Objective + Optimization	定义目标函数（ELBO、对抗损失、去噪得分匹配等）衡量分布差距；用梯度下降优化网络参数
推理	Inference	**Sampler**: 从模型中采样生成新样本

简要展开:

1. **收集观测数据**: 我们无法直接获知 $p(x)$，只能通过有限样本（图像、文本、蛋白质结构等）来近似它。
2. **构建可学习分布**: 用参数化模型（ 神经网络）拟合真实分布，最小化 $p_(x)$ 与 $p(x)$ 之间的某种“距离”（ KL 散度、Wasserstein 距离等）。
3. **生成新样本**: 训练完成后，从 $p_(x)$ 中采样，生成新的、看似合理的数据。

1.3 深度生成模型: 两个层面的学习

核心思想: 深度学习 = 表征学习（Representation Learning）

层面	内容	典型应用
实例表征 (instance-level)	将原始数据 x 映射到特征空间（ CNN 提取图像特征）	判别任务（分类），最小化预测误差

层面	内容	典型应用
分布表征 (distribution-level)	将简单先验 $z(0, I)$ 经神经网络变换为复杂数据分布 $x = G(z)$	生成任务，最小化 $p_(x)$ 与 $p(x)$ 的差异；典型代表: VAE、GAN、Diffusion Models、自回归模型

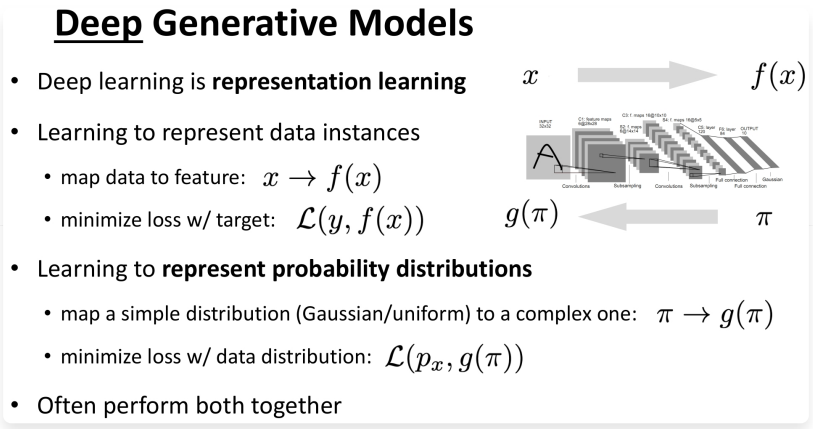


图3 深度生成模型的表征学习（实例表征，分布表征）

1.4 条件建模: $p(xy)$ 视角

前述从 $p_(x)$ 采样得到的生成是**随机的**，我们往往还需要**有条件的生成**——即根据用户意图（ 文本提示、类别标签、属性约束等）来控制生成内容。这便引入了条件建模的视角。

生成模型的本质是建模**条件分布** $p(xy)$:

变量	含义	示例
y（条件/意图）	更抽象、信息量更少的输入	文本提示（prompt）、约束（ 蛋白质对称性）、标签（ “红狐狸”）、属性（ “微笑”“戴眼镜”）
x（生成对象）	更具体、信息量更丰富的输出	图像、视频、3D 模型、蛋白质序列、传感器读数、实验数据等

典型应用场景:

任务	y（条件）	x（生成结果）
文生图	“泰迪熊在讲课”	图像
蛋白质设计	对称性约束	3D 蛋白质结构
图像分类（生成视角）	输入图像	类别概率 $p(x)$
机器人控制	视觉观测	动作策略 $p(as)$
图像描述	输入图像	自然语言句子

---

2. 从概率建模开始: 两条主线

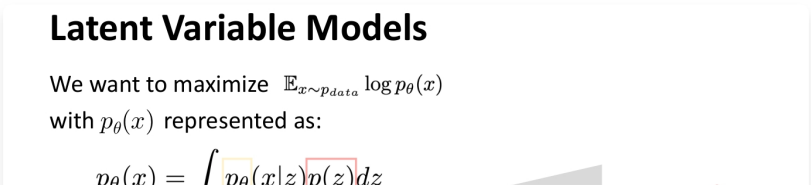
首先需要具备**概率论与生成模型的基础**，建议先阅读 机器学习篇-01.生成模型基础。

对联合分布 $p(x)$ 的建模有两条经典路径:

分解方式	数学形式	对应模型
条件概率分解	$p(x) = p(x_1, x_2) = p(x_1), p(x_2 x_1)$	**自回归模型（AR）**
边缘概率分解	$p(x) = p(x, z), dz = p(xz), p(z), dz$	**潜变量模型（Latent Variable Model）**

因此，从建模形式上看，生成模型可大致分为: **自回归模型** 与 **潜变量模型**。下面主要沿**潜变量模型**这条线展开；沿**自回归模型**这条线可参阅 AR系列篇-01.AR理论篇。

2.1 潜变量模型中的两个核心问题



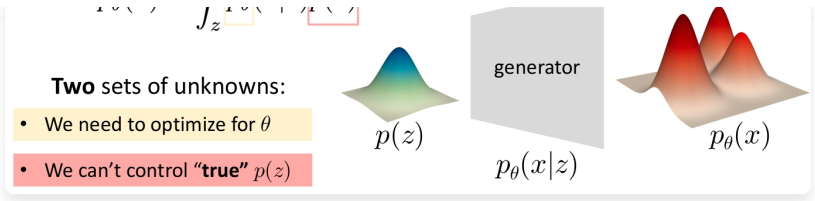


图4 潜变量模型框架与待解决问题

针对这些问题，可采取三种不同的思路，对应 AE/VAE、GAN、DM 三条分支。

2.2 方案一: 引入提议分布与 ELBO → VAE

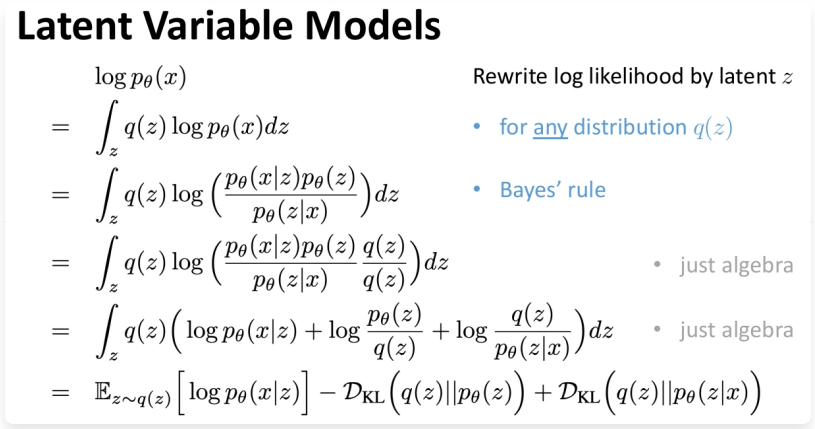


图5 从提议分布 q(z) 到 ELBO 与 VAE

建议阅读顺序:

- 机器学习篇-03.潜变量估计
- 机器学习篇-04.变分推断
- AE系列篇-01.AE
- AE系列篇-02.VAE理论篇

2.3 方案二: 引入判别器 → GAN

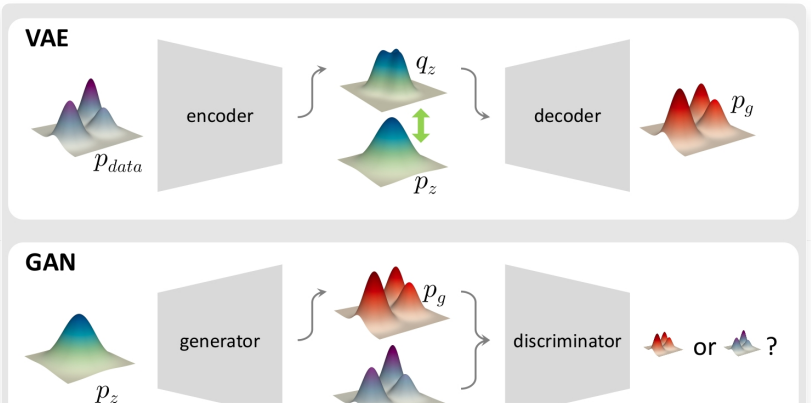




图6 在生成端引入判别模型得到 GAN

建议阅读:

- GAN系列篇-01.GAN理论篇
- 补充系列篇-04.生成模型与判别模型

2.4 方案三: 自回归 + 潜变量 → 扩散模型（DM）

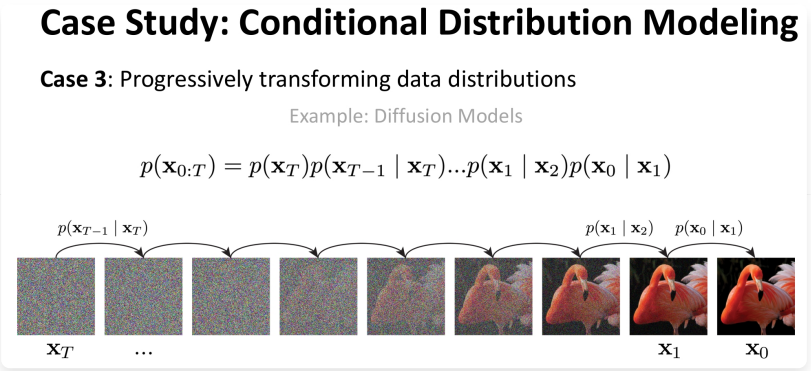


图7 从条件概率/分层 VAE 到扩散模型

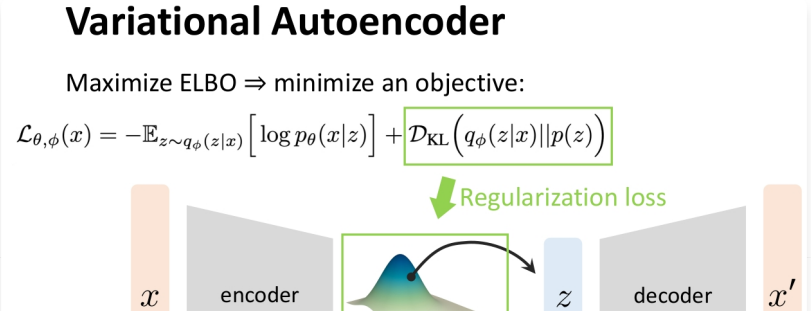
建议阅读:

- DM系列篇-01.DPM
- DM系列篇-02.不同形式的DPM

---

3. 训练: 从重构误差到正则化

VAE、GAN、DDPM 的目标函数可以统一理解为: 在**重构误差**的基础上，施加不同形式的**正则化**（或等价的变体）。下图概括了三者的差异。



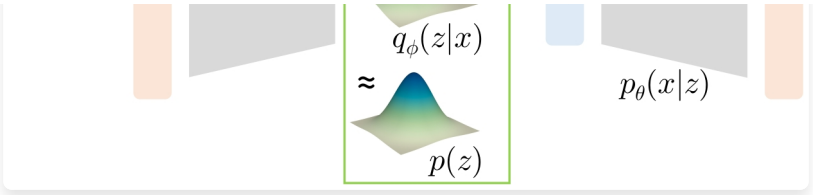


图8 VAE 的损失: 重构误差 + 潜变量正则化

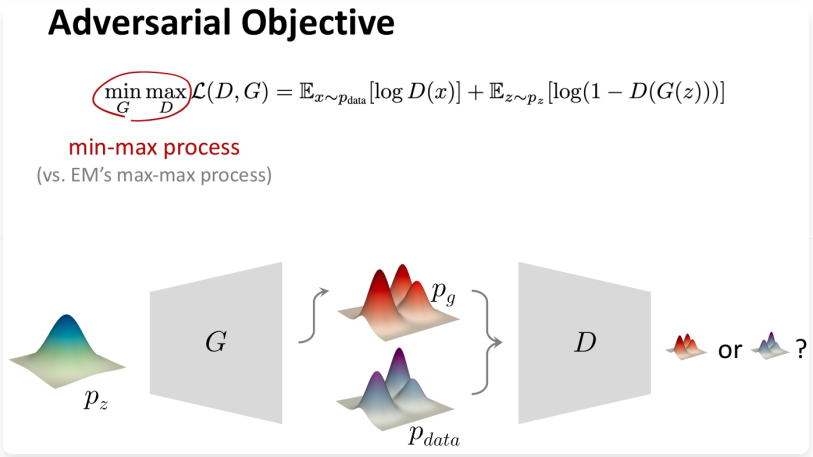


图9 GAN 的损失: 重构误差的替代 + “博弈”正则化

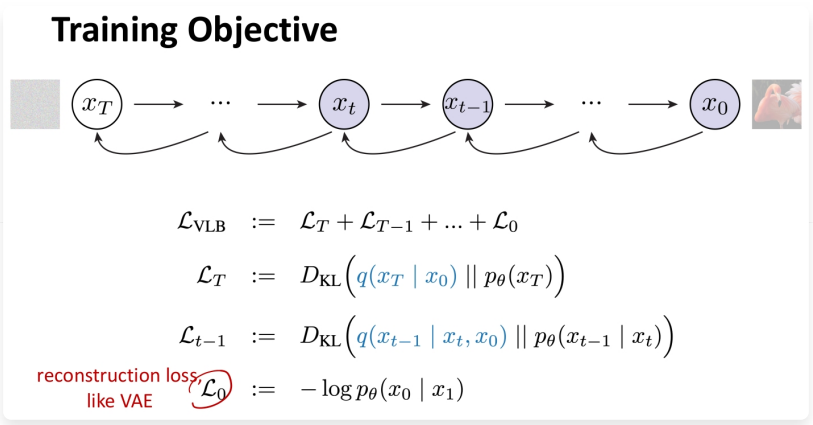


图10 DDPM 的损失: 仅与去噪相关的“重建”项

若想深入理解“为什么 KL 散度的方向不能反”“为什么潜变量常取正态分布”等，可参阅:

- 机器学习篇-02.最大似然估计
- 补充系列篇-01.Mode
- 补充系列篇-02.Why正态分布
- 补充系列篇-03.潜变量的可解释性

---

4. 采样: 从无条件到条件生成

有了前面的理论铺垫，若希望**动手实现**并验证算法，可依次阅读各系列的代码篇（建议先读对应理论篇）：

- AE系列篇-03.VAE代码篇
- DM系列篇-03.DDPM实现
- DM系列篇-04.DPM三种实现对比
- GAN系列篇-02.GAN代码篇
- AR系列篇-01.AR理论篇、AR系列篇-02.AR代码篇

实现后会发现:**无条件**生成的结果是随机的，无法按“类别”“文本”等条件控制输出。下一步自然过渡到**条件生成**: 从 Vanilla 版本扩展到 Conditional 版本。

条件生成相关阅读:

- AE系列篇-04.CVAE理论篇
- AE系列篇-05.CVAE代码篇
- DM系列篇-05.CDDPM理论篇1、DM系列篇-06.CDDPM理论篇2
- DM系列篇-07.CDDPM实现篇1、DM系列篇-08.CDDPM实现篇2
- GAN系列篇-03.CGAN理论篇
- GAN系列篇-04.CGAN代码篇
- AR系列篇-03.CAR

至此，你已经建立起**生成模型的基础知识体系**。

---

5. 生成模型的改进与进阶

基础算法在实际中往往存在局限，需要针对性地改进:

- **VAE**（连续潜变量难以表达离散、多模态） → 离散化与矢量量化: AE系列篇-06.VAE的改进篇1-VQ-VAE
- **DDPM**（采样步数多、速度慢） → 确定性采样与步数压缩: DM系列篇-09.DDPM的

改进1-DDIM

- **GAN**（训练不稳定、梯度消失）→ 用 Wasserstein 距离替代 JS 散度: GAN系列篇-05.GAN的改进1-WGAN

在此基础上，可进一步过渡到近年广泛使用的**条件扩散与潜空间扩散**（ LDM、CFG，也是 Stable Diffusion 等模型的基础）：

- DM系列篇-06.CDDPM理论篇2
- DM系列篇-07.CDDPM实现篇1、DM系列篇-08.CDDPM实现篇2
- DM系列篇-10.DDPM的改进2-LDM

我们对上述内容做一总结: **图11** 概括了生成模型从基础到进阶的完整学习路径，便于读者按图索骥、按需选读。

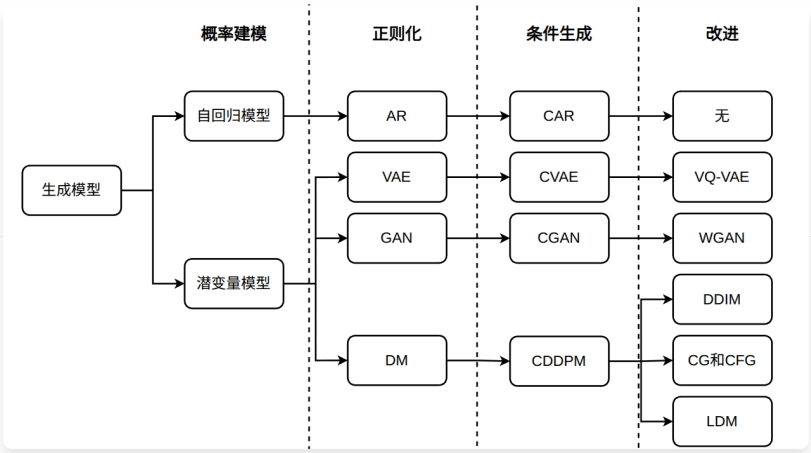


图11 生成模型学习路径

至此，你已经入门生成模型的主干内容。 后续可继续学习 **FM（Flow Matching）** 等扩展方向。