补充系列篇-01.Mode: Covering vs Mode Seeking

“Mode Covering” 和 “Mode Seeking” 是在概率建模、生成模型（ GANs、VAEs）以及变分推断等领域中常用来描述不同优化目标或行为的术语。它们的核心区别在于模型 何处理数据分布中的多模态性（multiple modes）。

---

1. 基本概念

1.1 Mode（模态）

在概率分布中，一个“mode”指的是概率密度局部最大的点。例 ，混合高斯分布可能有多个峰值，每个峰值就是一个 mode。

1.2 Mode Covering（模式覆盖）

- **又称**:zero-avoiding behavior 或 mean-seeking behavior
- **行为**:模型倾向于覆盖所有真实数据的模式，即使这意味着在某些低密度区域也会分配概率质量
- **优化目标**:通常与 KL 散度 $D_{KL}(p_{data}||p_{model})$ 相关
- **特点**:宁可“模糊”也不愿“遗漏”。比 生成图像时可能会产生平均脸（blurry average），但能覆盖各种类型

1.3 Mode Seeking（模式寻找）

- **又称**:zero-forcing behavior 或 mode-seeking behavior
- **行为**:模型倾向于只拟合它最有把握的那些模式，忽略其他不太确定的模式
- **优化目标**:通常与反向 KL 散度 $D_{KL}(p_{model}||p_{data})$ 相关

- **特点**:生成结果更锐利（sharp），但可能只集中在少数几个模式上，甚至只一个（即 mode collapse）。**注意**:Mode Seeking 行为容易导致 mode collapse，但 mode collapse 是后果而非同义词

---

2. 数学视角（以 KL 散度为例）

设真实数据分布为 $p(x)$，模型分布为 $q(x)$。

KL 散度方向	公式	行为	名称
Forward KL	$D_{KL}(p\|q) = \mathbb{E}_p\left[\log \frac{p}{q}\right]$	当 $p(x) > 0$ 但 $q(x) \approx 0$ 时惩罚极大 → q 必须覆盖 p 的所有支撑集	**Mode Covering**
Reverse KL	$D_{KL}(q\|p) = \mathbb{E}_q\left[\log \frac{q}{p}\right]$	当 $q(x) > 0$ 但 $p(x) \approx 0$ 时惩罚极大 → q 会避开 p 的低密度区，只集中在高置信区域	**Mode Seeking**

📌 **简单记忆**: - 前向 KL（$p\|q$）→ 覆盖（covering） - 反向 KL（$q\|p$）→ 寻找（seeking）

2.1 数学直觉

Forward KL ($D_{KL}(p\|q)$):

$$D_{KL}(p\|q) = \int p(x) \log \frac{p(x)}{q(x)} dx$$

- 期望在 $p(x)$ 下计算，所以 $p(x)$ 大的地方权重高
- 果 $p(x) > 0$ 但 $q(x) \approx 0$，$\log \frac{p(x)}{q(x)} \to +\infty$，惩罚极大
- **结果**:q 必须在所有 $p(x) > 0$ 的地方都有非零概率，即覆盖所有模式

Reverse KL ($D_{KL}(q\|p)$):

$$D_{KL}(q\|p) = \int q(x) \log \frac{q(x)}{p(x)} dx$$

- 期望在 $q(x)$ 下计算，所以 $q(x)$ 大的地方权重高
- 果 $q(x) > 0$ 但 $p(x) \approx 0$，$\log \frac{q(x)}{p(x)} \to +\infty$，惩罚极大
- **结果**:q 会避开 $p(x) \approx 0$ 的区域，只集中在 $p(x)$ 大的地方，即只寻找高概率模式

---

3. 代码实现与可视化

3.1 代码结构

我们使用 Python 实现一个可视化实验，展示 Forward KL 和 Reverse KL 在拟合双峰分布时的不同行为。

代码位置: `code/dl/gan/mode.py`

3.2 核心类:GaussianMixture1D

```python
class GaussianMixture1D:
    """一维高斯混合模型"""
    def __init__(self, mixture_probs, means, stds):
        self.num_mixtures = len(mixture_probs)
        self.mixture_probs = mixture_probs  # 混合权重
        self.means = means                  # 各分量的均值
```

```
        self.stds = stds                    # 各分量的标准差
```

关键方法: - `logpdf(samples)`: 计算对数概率密度，使用 `scipy.special.logsumexp` 避免数值下溢 - `pdf(samples)`: 计算概率密度

3.3 KL 散度计算

```
def approx_kl(gmm_1, gmm_2, xs):
    """使用数值积分近似计算 KL 散度"""
    ys = gmm_1.pdf(xs) * (gmm_1.logpdf(xs) - gmm_2.logpdf(xs))
    return np.trapz(ys, xs)  # 梯形积分
```

说明: - 使用梯形积分法（`np.trapz`）在离散点集上近似积分 - 公式: $D_{KL}(gmm_1 \| gmm_2) = \int gmm_1(x) \log \frac{gmm_1(x)}{gmm_2(x)} dx$

3.4 两种优化函数

Forward KL 优化（Mode Covering）:

```
def minimize_pq(p, xs, q_means, q_stds):
    """最小化 KL(p || q)，找到最优的单峰高斯 q"""
    # 遍历所有可能的 q 参数组合
    for q_mean in q_means:
        for q_std in q_stds:
            q = GaussianMixture1D(np.array([1]),
        np.array([q_mean]), np.array([q_std]))
            kl = approx_kl(p, q, xs)  # 计算 KL(p || q)
            # 找到最小的 KL 值
```

Reverse KL 优化（Mode Seeking）:

```
def minimize_qp(p, xs, q_means, q_stds):
    """最小化 KL(q || p)，找到最优的单峰高斯 q"""
    # 遍历所有可能的 q 参数组合
    for q_mean in q_means:
        for q_std in q_stds:
            q = GaussianMixture1D(np.array([1]),
        np.array([q_mean]), np.array([q_std]))
            kl = approx_kl(q, p, xs)  # 计算 KL(q || p)
            # 找到最小的 KL 值
```

3.5 实验设置

```
def main():
    # 创建5个不同的双峰分布 p
    # 每个 p 由两个等权重的高斯组成:
    # - 第一个分量:均值=0, 标准差=1
    # - 第二个分量:均值=p_second_mean (从0到10变化), 标准差=1

    p_second_mean_list = np.linspace(0, 10, 5)  # [0, 2.5, 5, 7.5,
        10]

    for p_second_mean in p_second_mean_list:
        # 创建双峰分布 p
        p = GaussianMixture1D(
            mixture_probs=np.array([0.5, 0.5]),
            means=np.array([0, p_second_mean]),
            stds=np.array([1, 1])
        )

        # 找到最优的单峰高斯 q
        q_best_forward = minimize_pq(p, ...)   # Forward KL
        q_best_reverse = minimize_qp(p, ...)   # Reverse KL
```

3.6 可视化结果

运行代码后，会生成包含5个子图的图像　图1所示，每个子图显示:

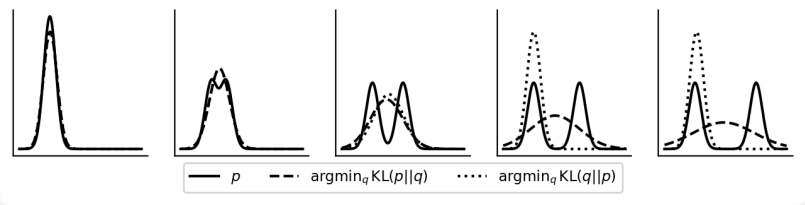


图1 Forward KL vs Reverse KL 对比:展示了5个不同的双峰分布（从左到右，两个峰的距离逐渐增大），以及 Forward KL 和 Reverse KL 在拟合这些分布时的不同行为。

- **实线**:原始双峰分布 p（两个高斯分量的混合）
- **虚线**:$\text{argmin}_q D_{KL}(p||q)$ - Forward KL 的最优 q（Mode Covering）
- **点线**:$\text{argmin}_q D_{KL}(q||p)$ - Reverse KL 的最优 q（Mode Seeking）

图中从左到右展示了5个子图，分别对应不同的双峰分布参数（μ_2 从 0 到 10 递增，其中 μ_2 是第二个高斯分量的均值）:

1. **第1个子图**（$\mu_2 = 0$）：
   - 两个峰几乎重叠（因为两个分量的均值都是0）
   - Forward KL 和 Reverse KL 的结果相似
   - 都尝试用一个单峰高斯覆盖两个峰
2. **第2个子图**（$\mu_2 = 2.5$）：
   - 两个峰开始分离，但距离较近
   - Forward KL 的 q（虚线）:尝试用一个较宽的高斯覆盖两个峰
   - Reverse KL 的 q（点线）:开始显示出只覆盖其中一个峰的倾向
3. **第3个子图**（$\mu_2 = 5$，中间位置）：
   - 两个峰明显分离
   - Forward KL 的 q（虚线）:尝试用一个较宽的高斯覆盖两个峰，位于中间位置
   - Reverse KL 的 q（点线）:明显只覆盖其中一个峰，忽略另一个
4. **第4个子图**（$\mu_2 = 7.5$）：
   - 两个峰距离进一步增大
   - Forward KL 的 q:仍然尝试覆盖两个峰，但变得很宽
   - Reverse KL 的 q:明确地只覆盖其中一个峰
5. **第5个子图**（$\mu_2 = 10$，最右侧）：
   - 两个峰完全分离
   - Forward KL 的 q:仍然尝试覆盖两个峰，但变得非常宽
   - Reverse KL 的 q:明确地只覆盖其中一个峰（mode collapse）

3.7 直观例子

假设真实数据分布是两个分离的高斯峰（双峰分布）：

Mode Covering 模型: - 会尝试用一个宽泛的分布（比 一个宽高斯，或两个都拟合）去覆盖两个峰 - 即使中间低密度区也被赋予一定概率 - **优点**:不会遗漏任何模式 - **缺点**:可能过于平滑，缺乏细节

Mode Seeking 模型: - 可能只拟合其中一个峰（因为它不想“冒险”跑到真实分布概率低的地方） - 导致另一个峰完全被忽略 - **优点**:生成结果锐利、细节丰富 - **缺点**:容易 mode collapse，多样性不足

---

4. 在生成模型中的体现

模型类型	典型优化目标	行为倾向	特点
VAE	最小化 $D_{KL}(q(z\|x)\|\|p(z))$ + 重构项（本质是 ELBO，对应前向 KL 近似）	倾向 **Mode Covering**	生成多样但可能模糊
GAN	极小极大博弈，等价于最小化 JS 散度（Jensen-Shannon），但在实践中梯度问题使其行为类似反向 KL	倾向 **Mode Seeking**	生成锐利但可能 mode collapse

4.1 VAE 的 Mode Covering 行为

VAE 的损失函数（ELBO）:

$$\mathcal{L}_{VAE} = \mathbb{E}_{q(z|x)}[\log p(x|z)] - D_{KL}(q(z|x)||p(z))$$

- 重构项鼓励精确重建
- KL 项 $D_{KL}(q(z|x)||p(z))$ 是反向 KL，但整体优化目标（通过变分下界）近似于前向 KL
- **结果**:VAE 倾向于生成所有可能的变体，导致“平均”效果，图像可能模糊

4.2 GAN 的 Mode Seeking 行为

GAN 的优化目标:

$$\min_G \max_D V(D,G) = \mathbb{E}_{x\sim p_{data}}[\log D(x)] + \mathbb{E}_{z\sim p_z}[\log(1-D(G(z)))]$$

- 理论上等价于最小化 JS 散度
- 但在实践中，由于梯度消失等问题，生成器的行为类似最小化反向 KL
- **结果**:GAN 生成锐利的图像，但容易陷入 mode collapse，只生成少数几种模式

---

5. 总结对比表

特性	Mode Covering	Mode Seeking
KL 方向	$D_{KL}(p_{data}\|\|p_{model})$	$D_{KL}(p_{model}\|\|p_{data})$
生成质量	多样但可能模糊	锐利但可能单一
风险	过于平滑、缺乏细节	Mode collapse
典型模型	VAE, MLE-based models	GAN（标准）
目标	覆盖所有真实模式	聚焦高置信模式
数学行为	当 $p(x) > 0$ 时，$q(x)$ 必须 > 0	当 $p(x) \approx 0$ 时，$q(x)$ 会 ≈ 0
适用场景	需要完整覆盖数据分布	需要高质量、锐利的生成结果

参考文献

1. Goodfellow, I., et al. (2014). Generative adversarial nets. *Advances in neural information processing systems*, 27.
2. Kingma, D. P., & Welling, M. (2013). Auto-encoding variational bayes. *arXiv preprint arXiv:1312.6114*.

3. Salimans, T., et al. (2016). Improved techniques for training gans. *Advances in neural information processing systems*, 29.

4. Minka, T. (2005). Divergence measures and message passing. *Microsoft Research Technical Report*.

5. https://www.tuananhle.co.uk/notes/reverse-forward-kl.html