补充系列篇-03.潜变量的可解释性

0. 概述

我们之前介绍了AE、VAE、CVAE（c与z相互独立）、CVAE_prior（c与z非独立），了解了latent变量的概念，也知道了正则化和条件对于z的影响，但是还没有直观性地了解z。

接下来我们设置 `latent_dim=2` ，通过2D可视化来直观解释一下latent变量，主要探讨以下几个问题:

1. **latent的分布**:AE和VAE的潜在空间分布有何不同?
2. **正则化的意义**:KL散度正则化　何影响潜在空间的分布和生成能力?
3. **条件对latent的影响**:条件信息　何改变潜在空间的分布?
4. **编码对latent的影响**:条件编码方式（one-hot vs embedding）　何影响模型的扩展能力?

---

1. Latent的分布

1.1 AE vs VAE:架构对比

AE（自编码器）和**VAE（变分自编码器）**在潜在空间的处理上有本质区别:

- **AE**:编码器直接输出潜在向量z，没有正则化约束
- **VAE**:编码器输出分布参数(μ, σ)，通过重参数化技巧采样z，并用KL散度正则化潜在空间

让我们先通过架构图直观对比两者的区别:



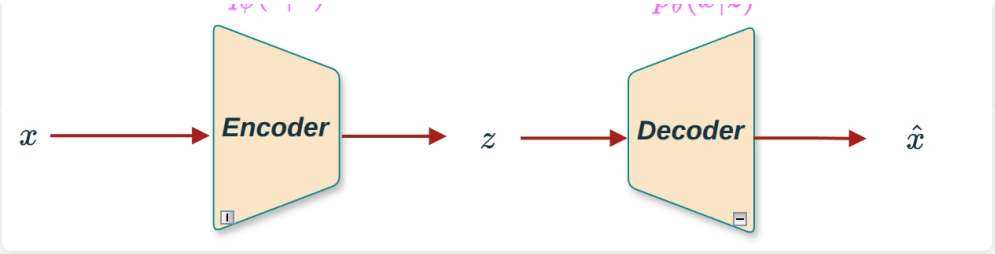


图1 AE架构:编码器直接输出潜在向量 z，解码器重构输出 $\hat{x}$

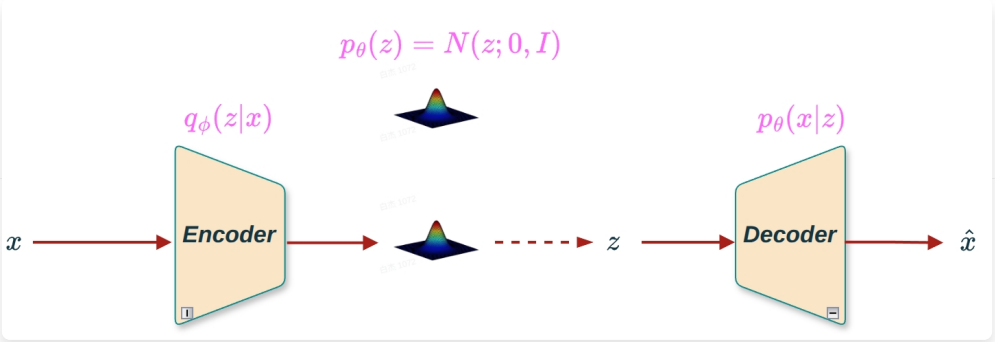


图2 VAE架构:编码器输出分布参数 (μ, σ)，通过重参数化技巧采样 z，并用KL散度正则化潜在空间

关键区别:

1. **编码器输出**:
   - AE: $z = \text{Encoder}(x)$（直接输出向量）
   - VAE: $\mu, \sigma = \text{Encoder}(x)$，然后 $z = \mu + \epsilon \cdot \sigma$，其中 $\epsilon \sim \mathcal{N}(0, I)$（输出分布参数，通过重参数化采样得到向量）
2. **潜在空间正则化**:
   - AE:没有正则化约束，潜在空间分布任意，可能存在“空洞”
   - VAE:通过KL散度 $\text{KL}(q(z|x)||\mathcal{N}(0, I))$，将潜在空间约束到标准正态分布
3. **损失函数**:
   - AE: $\mathcal{L} = ||\hat{x} - x||^2$（只有重构损失）
   - VAE: $\mathcal{L} = ||\hat{x} - x||^2 + \beta \cdot \text{KL}(q(z|x)||\mathcal{N}(0, I))$（重构损失 + KL散度正则化项）

这些架构上的差异直接影响潜在空间的分布特性。接下来我们通过2D可视化来直观对比两者的潜在空间分布:

1.2 AE vs VAE:潜在空间分布对比

让我们通过2D散点图来直观对比两者的潜在空间分布:

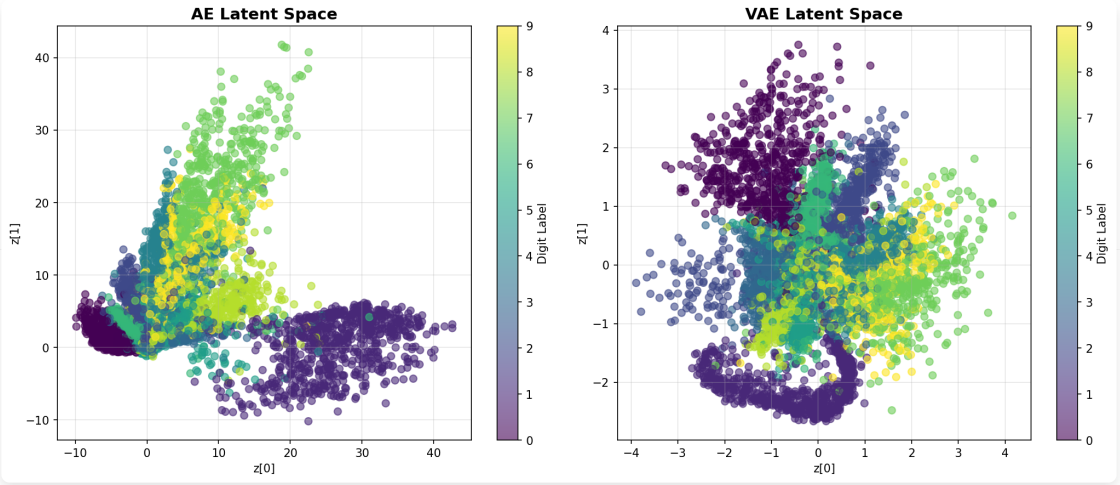


图3 AE和VAE的潜在空间分布对比（latent_dim=2）

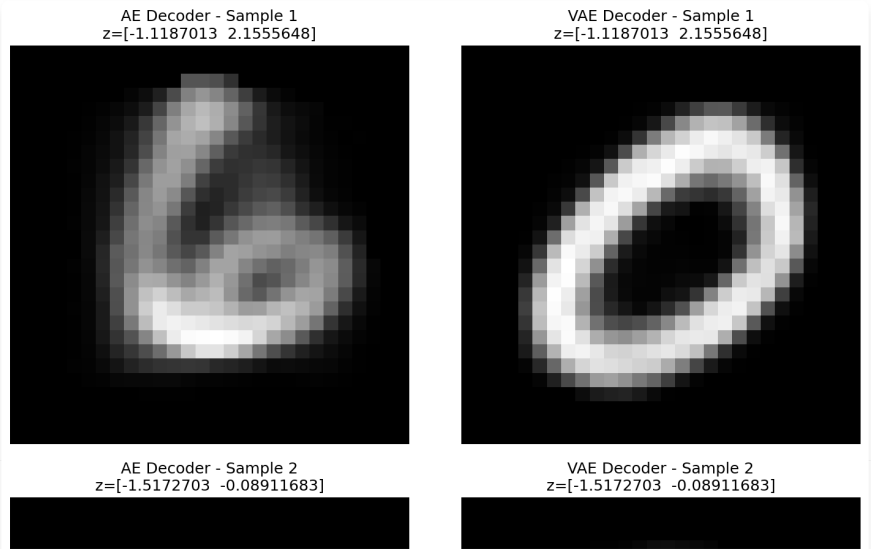
从图中可以观察到:

- **AE的潜在空间**:数字的分布比较混乱，没有明显的结构。不同数字的潜在表示可能重叠，且分布不规律。
- **VAE的潜在空间**:由于KL散度的正则化，潜在表示趋向于聚集在原点附近，形成更紧密的簇状结构。

1.3 从潜在空间采样生成

关键问题:潜在空间是否具有生成能力？即能否从潜在分布中采样得到有意义的样本?

让我们从**标准正态分布**采样2个潜在向量z，分别使用AE和VAE的解码器生成图像:



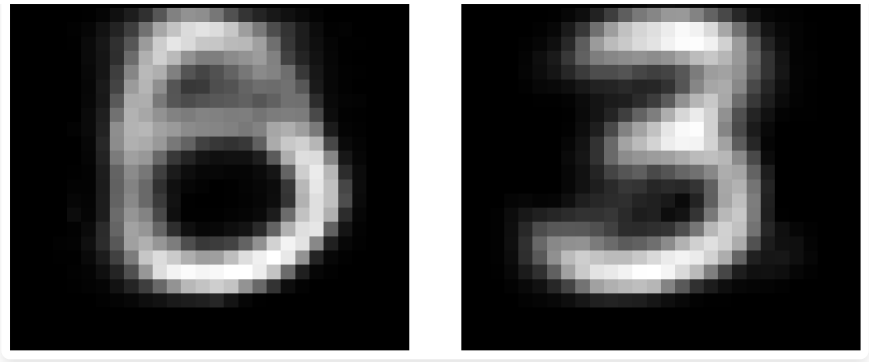


图4 从标准正态分布采样 z，使用AE和VAE解码器生成的图像对比

观察结果:

- **AE**:从标准正态分布采样的 z，通过AE解码器生成的图像往往没有意义。这是因为AE没有正则化潜在空间，潜在分布与标准正态分布不匹配。
- **VAE**:从标准正态分布采样的 z，通过VAE解码器能够生成合理的数字图像。这是因为VAE通过KL散度正则化，使得潜在空间接近标准正态分布。

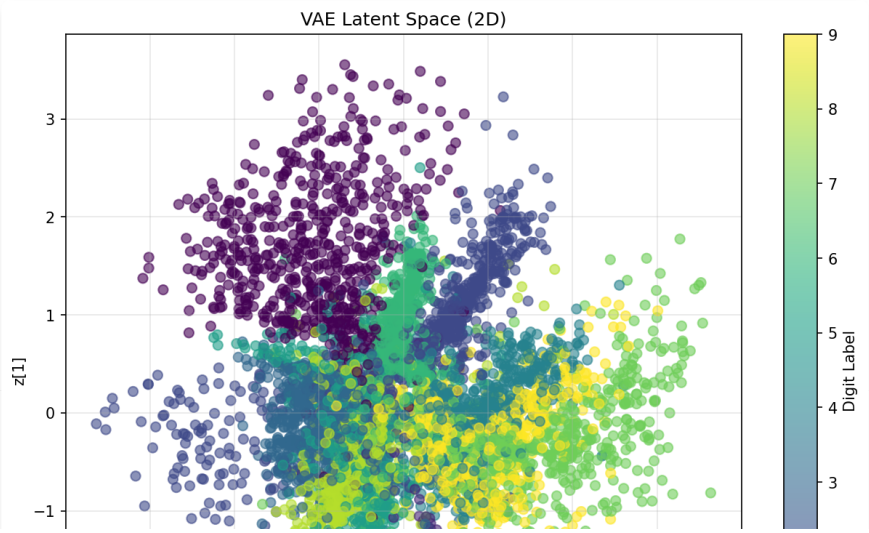
核心结论:AE的latent没有明确的分布，缺乏生成能力；VAE的latent遵循标准正态分布，具有强大的生成能力。

---

2. 正则化的意义

2.1 VAE潜在空间的分布特性

VAE通过KL散度正则化，使得潜在空间 $q(z|x)$ 接近标准正态分布 $\mathcal{N}(0, I)$。让我们单独查看VAE的潜在空间分布:



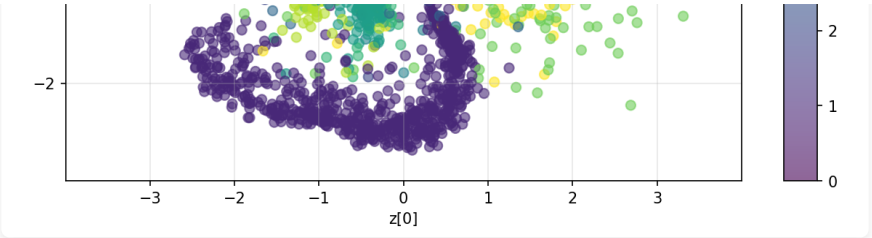


图5 VAE的潜在空间分布（latent_dim=2，使用 μ 表示）

观察要点:

1. **分布特性**:潜在表示大致围绕原点分布，符合标准正态分布的特性
2. **数字分离**:不同数字的潜在表示虽然可能重叠，但整体上有一定的分离趋势
3. **颜色编码**:不同颜色代表不同的数字标签（0-9），从深到浅表示0到9

2.2 潜在空间的“叠加性”（Interpolation）

正则化的另一个重要作用是使得潜在空间具有**连续性**和**叠加性**。这意味着可以在潜在空间中平滑地从一个点过渡到另一个点，生成的图像也会平滑地变化。

实验设计:

1. 从测试集获取一张数字1的图片和一张数字8的图片
2. 通过VAE编码器得到 z_1 和 z_8
3. 进行线性插值: $z = \alpha \cdot z_1 + (1 - \alpha) \cdot z_8$，其中 α 从1渐变到0
4. 将插值后的 z 输入解码器，观察生成的图像变化

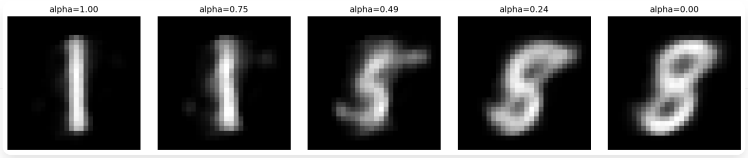
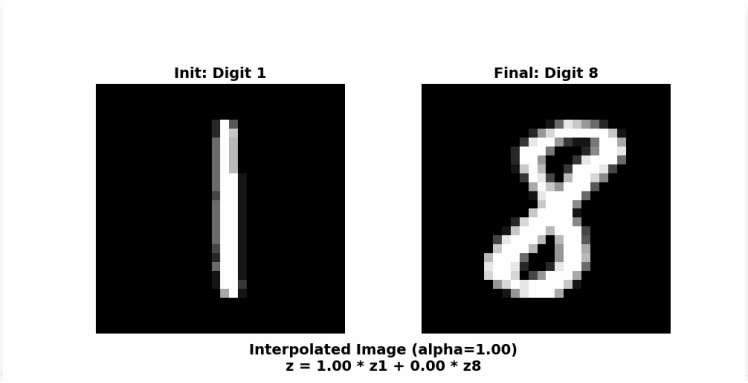


图6 VAE潜在空间插值:从数字1平滑过渡到数字8（关键帧）



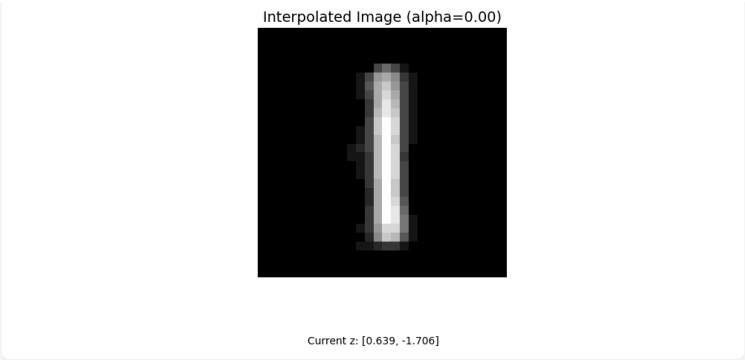


图7 VAE潜在空间插值动画:从数字1平滑过渡到数字8

关键发现:

- **平滑过渡**:插值过程中，生成的图像从数字1逐渐变化到数字8，中间过渡平滑自然
- **语义连续性**:潜在空间中的线性插值对应图像空间中的语义连续变化
- **生成能力**:这表明VAE的潜在空间是一个**连续且有意义的语义空间**

为什么AE不具备这种特性?

AE没有正则化约束，潜在空间的分布是任意的，因此: - 从标准正态分布采样的z无法生成有意义的图像 - 潜在空间中的插值可能导致生成图像的突变或不连续

正则化的核心意义:将潜在空间约束到标准正态分布，使得整个潜在空间都具有生成能力，并且潜在空间具有连续性和叠加性。

---

3. 条件对Latent的影响

在探讨条件对潜在空间的影响之前，让我们先对比VAE、CVAE和CVAE_prior的架构差异:

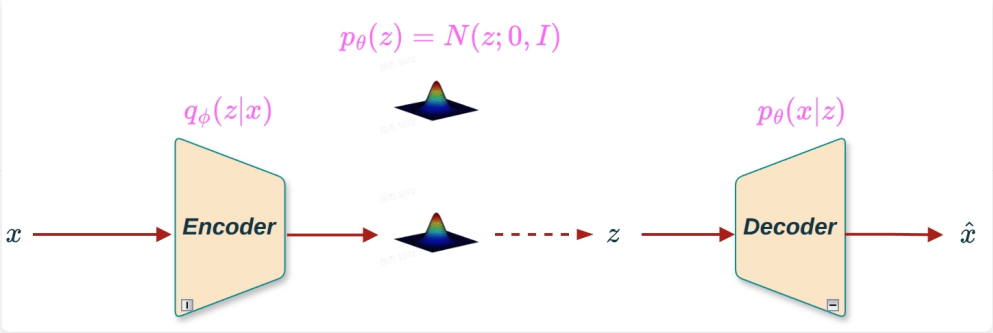


图8 VAE架构:编码器输出分布参数(μ, σ)，通过重参数化技巧采样z，并用KL散度正则化潜在空间

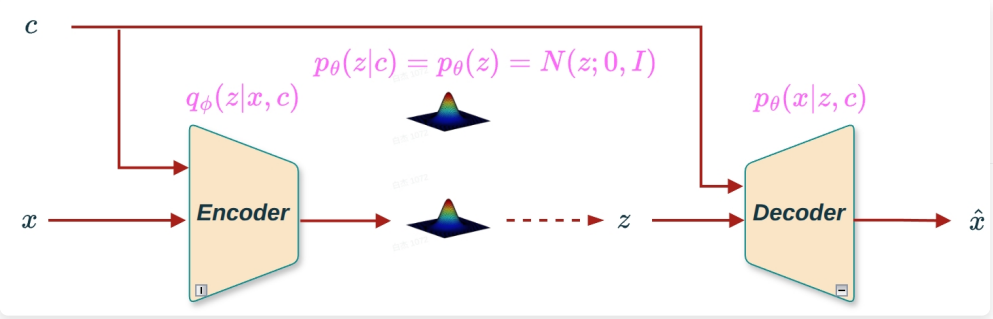


图9 CVAE架构:条件c与输入x拼接后输入编码器，条件c也与潜在向量z拼接后输入解码器（c与z相互独立）

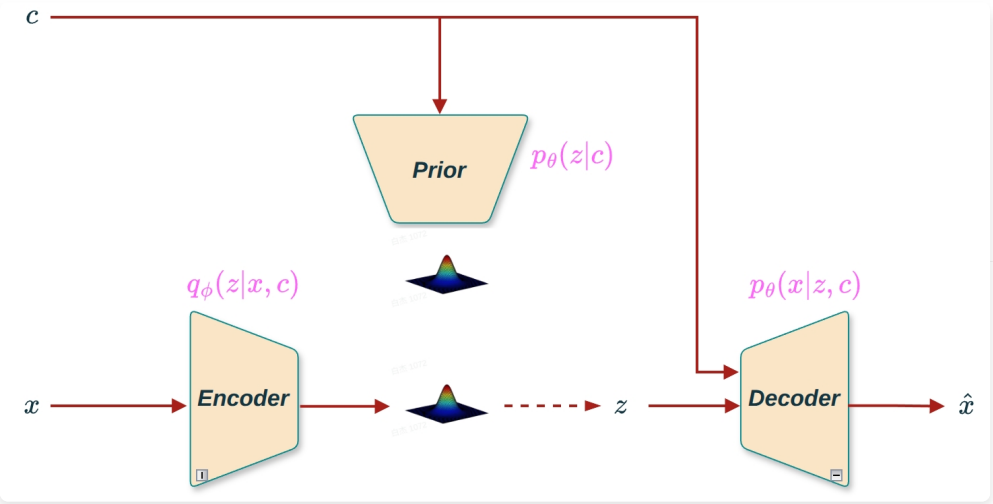


图10 CVAE_prior架构:条件c不仅影响编码器和解码器，还影响先验分布$p(z|c)$（c与z非独立）

架构对比:

1. **VAE**:
   - 无条件的生成模型
   - 先验分布:$p(z) = \mathcal{N}(0, I)$（标准正态分布）
   - 后验分布:$q(z|x) = \mathcal{N}(\mu(x), \sigma(x))$
2. **CVAE**:
   - 条件生成模型，条件c与潜在变量z相互独立
   - 先验分布:$p(z|c) = p(z) = \mathcal{N}(0, I)$（仍然是标准正态分布，不受$c$影响）
   - 后验分布:$q(z|x,c) = \mathcal{N}(\mu(x,c), \sigma(x,c))$
   - 编码器输入:$[x, c]$；解码器输入:$[z, c]$
3. **CVAE_prior**:

- 条件生成模型，条件c影响先验分布
- 先验分布:$p(z|c) = \mathcal{N}(\mu_p(c), \sigma_p(c))$（依赖于条件$c$）
- 后验分布:$q(z|x,c) = \mathcal{N}(\mu(x,c), \sigma(x,c))$
- 编码器输入:$[x, c]$；解码器输入:$[z, c]$；先验网络输入:c

关键区别:CVAE和CVAE_prior的主要区别在于先验分布是否依赖于条件。CVAE中$p(z|c) = p(z)$，条件只影响编码器和解码器；而CVAE_prior中$p(z|c)$是条件依赖的，先验网络会学习条件相关的先验分布。

3.1 CVAE中的条件控制

在CVAE中，条件变量c可以控制生成过程。让我们通过实验观察条件对潜在空间的影响。

实验设计:

1. 从标准正态分布采样一个固定的潜在向量z
2. 条件c从0到9渐变（使用embedding编码）
3. 将(z, c)输入CVAE解码器，观察生成的图像

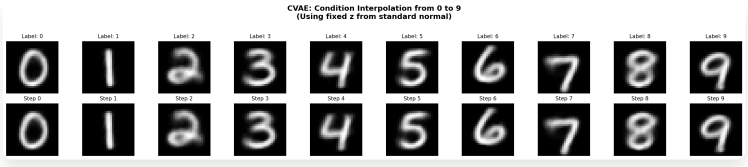
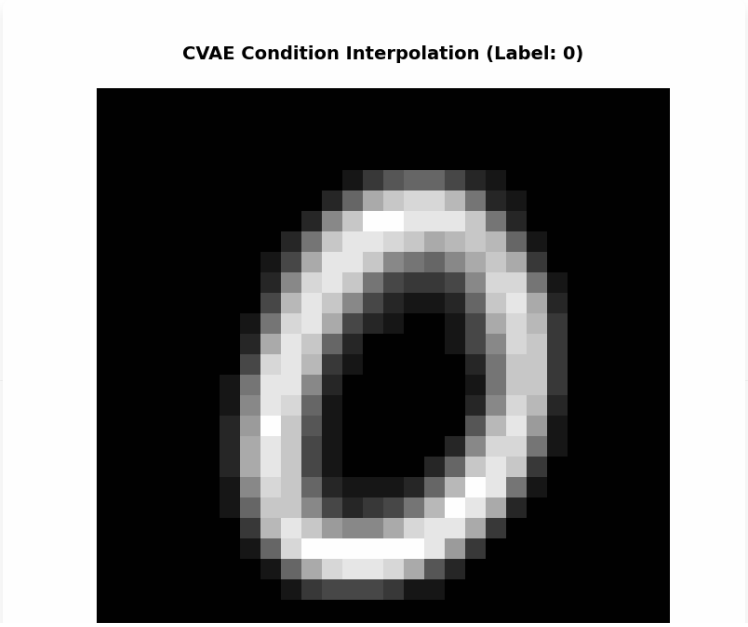


图11 CVAE条件插值:固定z，条件从0渐变到9（关键帧）



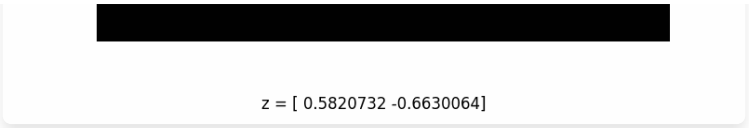


图12 CVAE条件插值动画:固定z，条件从0渐变到9

关键观察:

- **条件控制生成**:相同的潜在向量z，不同的条件c，生成的图像完全不同
- **条件改变分布**:条件c实际上改变了潜在空间的"有效分布"。虽然z不变，但条件与z的拼接(z, c)改变了解码器的输入，相当于改变了有效的潜在表示
- **条件作为"开关"**:条件就像是一个"开关"，决定了从同一个z生成什么类别的图像

数学理解:

在CVAE中，生成过程为$p(x|z, c)$。对于固定的z，条件c的作用是: - 在解码器中，条件c与潜在向量z拼接:$[z, c]$ - 不同的c导致不同的解码器输入，从而生成不同的输出 - 相当于条件改变了潜在空间的"视角"或"分布"

核心结论:条件信息可以控制生成过程，即使使用相同的潜在向量z，不同的条件也能生成完全不同类别的图像。这体现了CVAE在可控生成方面的优势。

---

4. 编码对Latent的影响

4.1 实验设计:部分数据训练与编码微调

前面的实验展示了条件对生成的影响。现在我们来探讨一个更深层次的问题:**条件编码方式如何影响模型的扩展能力?**

实验设置:

1. **训练阶段**:使用0-7的数字训练CVAE模型（排除8和9）
2. **测试阶段**:使用8和9的条件进行解码，观察生成效果（优化前）
3. **微调阶段**:冻结模型的所有参数，只优化embedding层，使用8和9的数据微调embedding
4. **对比阶段**:再次使用8和9的条件解码，观察优化后的效果

这个实验的关键在于:**模型从未见过8和9的训练数据，能否通过只优化embedding层来生成合理的8和9数字?**

4.2 实验结果:编码微调的效果

优化前的效果:

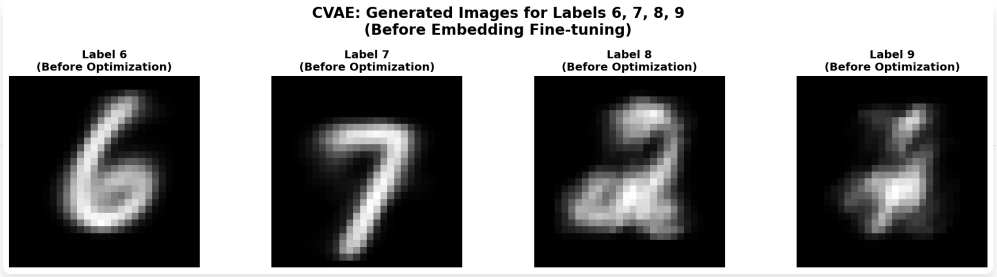


图13 优化embedding前:使用6、7、8、9条件生成的图像

观察: - 数字6和7:模型在0-7数据上训练，能够生成相对合理的图像 - 数字8和9:模型从未见过8和9的数据，生成的图像不准确或模糊

优化后的效果:

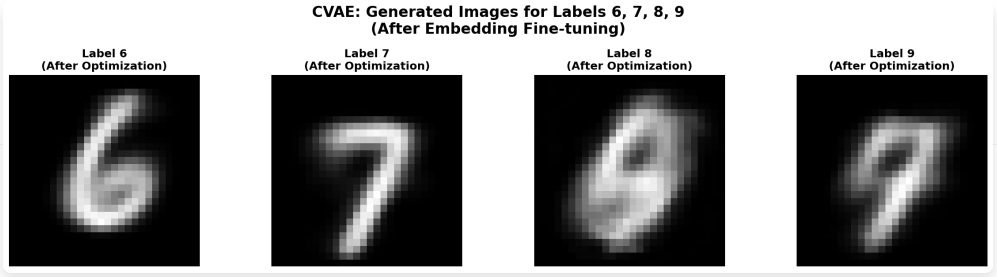


图14 优化embedding后:使用6、7、8、9条件生成的图像

对比分析:

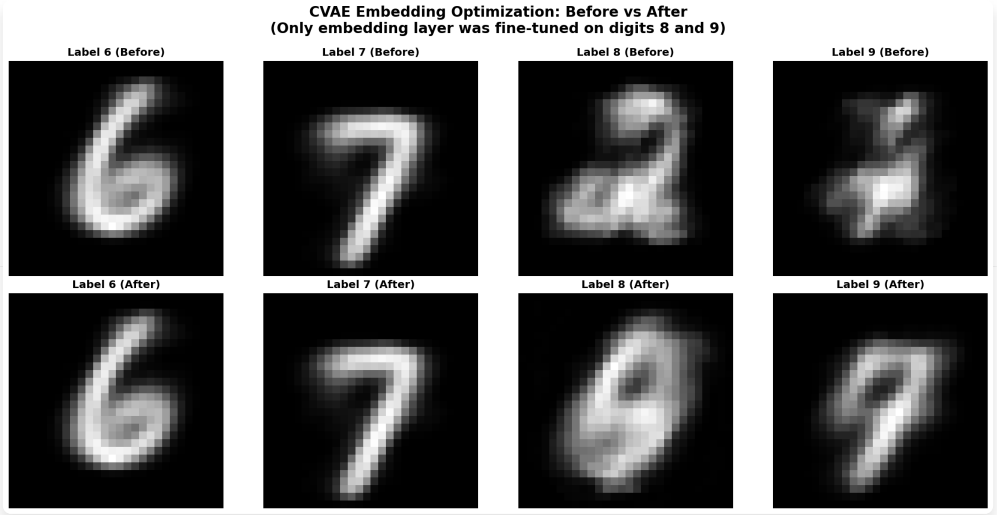


图15 优化前后对比:第一行为优化前，第二行为优化后

关键发现:

1. **数字8和9的改善**:
   - 优化前:生成的8和9图像模糊或不准确
   - 优化后:只优化embedding层后，模型能够生成更合理的8和9数字
2. **数字6和7的变化**:
   - embedding微调后，6和7的生成效果可能略有变化，但基本保持合理
3. **embedding的泛化能力**:
   - 即使模型的其他部分（编码器、解码器）没有见过8和9的数据
   - 只优化embedding层就能让模型生成合理的8和9数字
   - 这说明**embedding层具有强大的泛化能力**

4.3 多样本验证

为了进一步验证embedding微调的效果，我们使用多个不同的潜在向量 z 进行测试:

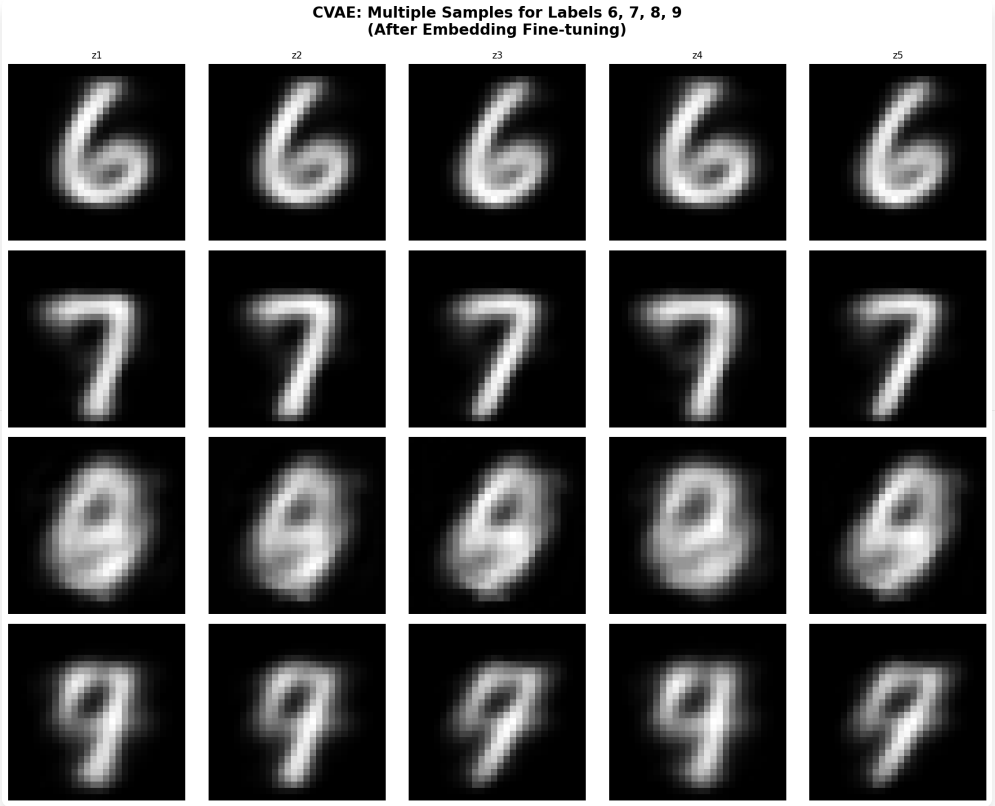


图16 多个样本对比:不同z值下生成的6、7、8、9图像（优化后）

观察: - 不同z值生成的图像有变化（体现了潜在空间的生成多样性） - 但每个数字都能保持其基本的视觉特征（体现了embedding的控制能力）

4.4 编码方式的影响

为什么embedding编码方式具有这种能力?

1. **Embedding的优势**:
   - Embedding是**可学习的低维表示**，能够捕获类别之间的语义关系
   - 在训练0-7的过程中，embedding学会了数字的语义特征
   - 当用8和9的数据微调时，embedding能够快速适应新的类别
2. **与One-Hot的对比**:
   - One-hot编码是**固定的、稀疏的**，无法学习语义关系
   - Embedding编码是**可学习的、密集的**，能够灵活调整
3. **参数效率**:
   - 只需要微调embedding层（相对较少的参数）
   - 不需要重新训练整个模型（编码器和解码器保持不变）

核心结论:

虽然本文并未对模型性能进行任何系统性的评估，但我们可以看到，**学习到的嵌入（embedding）对于向CVAE模型添加新条件非常有用，而无需重新训练整个模型**。

这说明了:

1. **Embedding编码的灵活性**:可以通过微调embedding来扩展模型到新的类别
2. **模型的模块化设计**:条件编码层与其他部分相对独立，便于扩展
3. **潜在空间的语义理解**:模型学会了数字的潜在语义，只需调整embedding就能适应新类别

---

5. 总结

通过设置 `latent_dim=2` 的2D可视化实验，我们直观地理解了潜变量的几个关键特性:

5.1 Latent的分布

- **AE**:潜在空间没有明确的分布，缺乏生成能力
- **VAE**:通过KL散度正则化，潜在空间接近标准正态分布，具有强大的生成能力

5.2 正则化的意义

- **分布约束**:KL散度将潜在空间约束到标准正态分布
- **连续性**:潜在空间具有连续性和叠加性，可以进行平滑插值
- **生成能力**:整个潜在空间都具有生成能力，可以从任意位置采样

5.3 条件对Latent的影响

- **条件控制**:条件变量c可以控制生成过程
- **分布改变**:条件改变了有效的潜在表示，即使z不变也能生成不同类别的图像
- **可控生成**:实现了从“随机生成”到“条件可控生成”的跨越

5.4 编码对Latent的影响

- **Embedding的泛化能力**:通过微调embedding层，可以为模型添加新的条件类别
- **参数效率**:只需微调少量参数（embedding），无需重新训练整个模型
- **模块化设计**:条件编码层相对独立，便于模型扩展

这些实验为我们理解变分自编码器的潜在空间提供了直观的认识，也为后续更复杂的生成模型（ GAN、扩散模型等）奠定了基础。

附录:实验代码

本节的实验代码位于 `code/dl/ae/ae_all/` 目录下:

- **test1_ae_vae.py**:对比AE和VAE从标准正态分布采样生成的图像
- **test2_vae.py**:VAE潜在空间插值动画（从数字1到8）
- **test3_cvae.py**:CVAE条件插值动画（条件从0到9渐变）
- **test4_cvae_embed.py**:Embedding微调实验（使用0-7训练，微调8和9的embedding）

所有代码都已实现 `latent_dim=2` 的2D可视化，便于直观理解潜在空间的特性。